

נושא:

Double-function enhancement algorithm for low-illumination images based on Retinex theory.

Discrete Cosine Transform-based Image Fusion

Ruslan31bar@gmail.com

Git : [LINK](#)

(ראה אופן שימוש עמ' 17) ([GUI DFE](#))

(ראה אופן שימוש עמ' 35) ([GUI DCT](#))

תוכן עניינים

Table of Contents

3	Double-function enhancement algorithm for low-illumination images based on Retinex theory
3	מבוא
3	Basic Theory
3	Retinex Theory
4	אלגוריתם
5	TV – denoise
6	Double-Function Image Enhancement
7	Three-Dimensional Gamma Correction
7	Saturation Regulation
8	תוצאות
17	הסבר על שימוש בGUI
18	Discrete Cosine Transform – based Image Fusion
18	מבוא
18	התמרת קווינוס בדידה
19	התמרת קווינוס בדידה רב רוחוציה
23	היתור
23	הערכת ביצועים
23	עם תמונה יהול
24	ללא תמונה יהול
25	תוצאות
35	הסבר על שימוש בGUI
37	References

Double-function enhancement algorithm for low-illumination images based on Retinex theory

מאמץ זה מציע אלגוריתם לשיפור תמונה באיכות גבוהה כדי לפחות את הבעיה של הגברת רעש ושיפור מוגזם כתוצאה מניגודיות נמוכה ותאורה לא אחידה בתחילת של שיפור תמונה בתאורה עם עצמה נמוכה. מודל הוריאציה הכללת משתמש להשתתת תונות ערוץ V ו-S מוחלקות, וטרנספורמציה גמא אדרטיבית משמשת לשיפור הפרטים בערך V של התמונה. לאחר מכן משתמשים באלגוריתם משופר של Retinex רב סולס לשגת תונות משופרות שונות של ערוץ V, ושתי התנות מתחזות בהתאם למפלילות העצמה המוקנית של התנות. לבסוף, פונקציית הגמא הבלתי מידי משמשת כדי לתקן את התמונה המוגזמת ולהתאים את רווחת התמונה.

מבוא

יש שתי הקטגוריות של אלגוריתמים לשיפור תמונה בתאורה נמוכה: אלגוריתמים מסורתיים ולמידה عمוקה. אלגוריתמים מסורתיים כוללים מיפוי, השוואת היסטוגרמָה, טרנספורמציה של Wavelets ותיאורית Retinex. שיטות המיפוי משתמשות בפונקציות לא ליניאריות לעיבוד גלובלי של תונות בתאורה נמוכה ומתאימות את משראת השיפור של אזורים שונים כדי למגוון עיוות תמונה. השוואת היסטוגרמָה יכולה להשיג את אפקט השיפור על ידי הרחבות הטווח הדינמי של התמונה. טרנספורמציה Wavelet יכולה לעבוד גם את תחום התדר וגם את התחום המרחבי של התמונה בו-זמנית. תיאורית ה-Retinex מחלקת תמונה לרכיבי אירוע ורכיב השתקפות ומסירה את רכיב האירוע מהתמונה המקורית כדי לקבל את רכיב החשתקפות. על פי מודלים שונים של נתיבים, ניתן לחלק אותו ל Retinex מבוססת נתיב אקרטי, Retinex מבוססת ריבוי איטרציות ו Retinex מבוססת מרכז/הקיף.

מאמץ זה מציע אלגוריתם מסורתי לשיפור תמונה תאורה נמוכה, תוך שימוש במודל הוריאציה הכללת (TV – Total Variation) כדי לטשטש את תונות ערוץ ה-V ואת טרנספורמציה הגמא ההסתגלותית כדי לשפר את הפרטים של תונות שכבת המבנה המתקבל לאחר ביטול רעש. פונקציית הטנגנס החיפרבולית והפונקציה הלוגריתמית משולבות כדי לשנות באמצעותם המשופרת. לבסוף, הרווחת התמונה מודנית משמשת להתחמת התמונה המפורטת ולתיקון התמונה המשופרת. לבסוף, הרווחת התמונה מותאמת על ידי סוף אוטומטי כדי לקבל את האפקט הסופי.

Basic Theory

Retinex Theory

הרעון המרכזי של Retinex הוא שתמונה מורכבת מרכיב אירוע ורכיב משתקף. עצמת רכיב האירוע קובעת את הטווח הדינמי של פיקסל תמונה, בעוד רכיב המשתקף הוא תכונה אינגרנטית של האובייקט ואינו משתנה עם רכיב האירוע. הדגש הוא כדלקמן:

$$I(x, y) = R(x, y) \cdot L(x, y)$$

כאשר (y, x) הוא תומנת התצפית, (y, x) הוא מרכיב החשתקפות ו- (y, x) L הוא מרכיב האירוע. בדרך כלל זה מומר לצורה לוגריתמית כדי להפחית את המורכבות החישובית:

$$\log R(x, y) = \log I(x, y) - \log L(x, y).$$

בהתבסס על תיאוריה זו, הוצע אלגוריתם SSR (single-scale retinex) קלאסי. פונקציית גרעין וגוש עובה קונבולוציה עם התמונה המקורית כדי להעניק את רכיב האירוע, ורכיב החשתקפות מתקבל כדי למש את השיפור של תונות בעלות תאורה נמוכה. הנוסחה היא כדלקמן:

$$\log R_i(x, y) = \log I_i(x, y) - \log(I_i(x, y) \otimes G(x, y))$$

כשאר גרעין גאוסיאני :

$$G(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

כאשר סטיטית תקן של גaus קטן, התמונה המשופרת שומרת יותר פרטים, אך היא עלולה לגרום בклות לעיוות צבע בתמונה. סטיטית תקן של גaus גדול, התמונה המשופרת שומרת על צבע טוב, אך התמונה הופכת למוטושתת, ואפקט ההילה מתרחש בклות באזור הבHIR יותר.

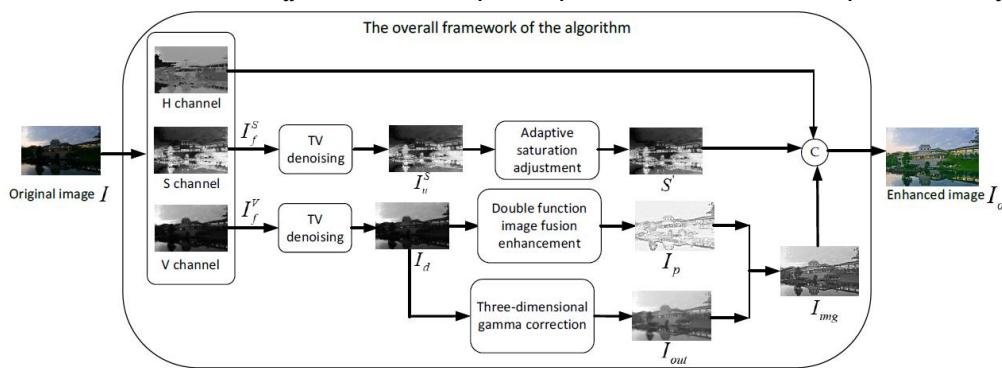
על מנת לפטור את הביעות הניל, הוצע אלגוריתם MSR(multi-scale retinex) לשיפור תמונות בהארה נמוכה בקנה מידה שונה, והביטוי שלו הוא כדלקמן :

$$\log R_i(x, y) = \sum_j^N \omega_j \{ \log I_i(x, y) - \log(I_i(x, y) \otimes G_j(x, y)) \}$$

כאשר $N=3$, המיצג את שלושת הדרגות, ω מיצג את המשקל של דרגת j , ובאופן כללי $\omega_1 = \omega_2 = \omega_3 = \frac{1}{3}$. G_j מיצג את פונקציית הגרעין הגaussית המתאימה עם סטיטית תקן שונה.

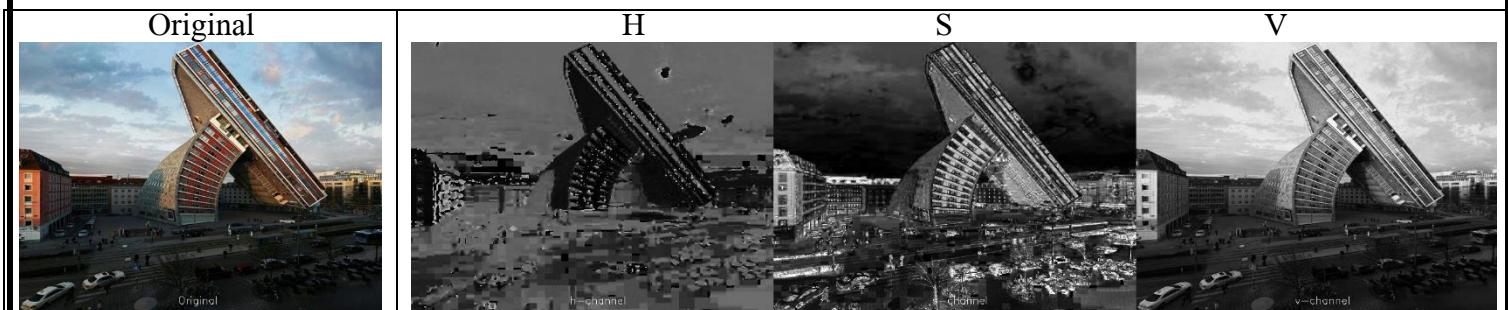
אלגוריתם

כדי להשיג ביצועי שיפור באיכות גבוהה ללא הגברת רעש במצב תוארה נמוכה, אלגוריתם עיל המבוסס על תיאורית Retinex. תרשימים הכוללים לאלגוריתם שיפור התמונה מוצגים באירור 1. האלגוריתם המוצע מורכב מיחידת TV denoising, יחידת התאמת רויה אדפטיבית, יחידת שיפור היתוך תמונה כפולה ויחידה תלת ממדית לתיקון גמא. התמונה המקורי היא תמונה הקלט בפורמט RGB, אשר מונרת תחילת לפורמט HSV, ולאחר מכן מתקבלות תמונות ערוץ S וערוץ V. I_{img}^S ו I_{img}^V מתקבלות באמצעות שיטות עיבוד שונות. לבסוף, תמונות שלושת הערוצים שהתקבלו מיוצרות מחדש HSV וRGB. יש להחליק את תמונה ערוץ V על ידי denoising TV כדי לקבל את התמונה I_u^V , ואז הפרטים משופרים על ידי שיפור גמא אדפטיבי כדי לקבל את התמונה I_d . יש להחליק את תמונה S-channel רק כדי לקבל את התמונה I_u^S .



איור 1. תרשימים זרימה של אלגוריתם

נראה את תוצר אלגוריתם בכל אחד מהשלבים בעזרת תמונה הבאה:



TV – denoise

על פי תיאורית הרטינקס, לאחר הסרת רכיב האירוע בתמונה, הרכיב המשתקף המתקבל יכול להראות את הצבע האמיתי של האובייקט, כך שלאלגוריתמים הקשורים המבוססים על תיאורית הרטינקס יש יכולת שימור צבע טוביה. בפועל, קשה להעירר במידוק את מרכיב האירוע בתמונה, מה שהוביל לליקויים ברכיב ההשתקפות המתקבל, להרווס את המתאים בין ערכי צבע, ולהוביל לעיוות צבע בתוצאה שייפור התמונה. כדי למנוע מצב זה, ניתן להעביר את התמונה למרחב HSV. באמצעות ניתוח תהליך ההמרה, נמצא שרשע התמונה יש לסנן טרנספורמציה מרכז בערך בערוצי S ו- V. לכן, כדי להפחית את הגברת הרעש בתהליך שייפור התמונה, יש לסנן תחיליה את ערכי התמונה הנ"ל. מבין שיטות הגינון המבוססות על משוואות דיפרנציאליות חילקוות, מודל TV- denoise הוכח כאחד האלגוריתמים היעילים ביותר. באמצעות מודל זה, ניתן להפוך את בעיית הניפוי התמונה לבעית אופטימיציה כדי לפתור את פונקציית האנרגיה המינימלית, והיבטי מוצג כדלקמן:

$$\min_{I_u^c} E(I_u^c) = \min_{I_u^c} \iint_{\Omega} |\nabla I_u^c| dx dy + \frac{\lambda}{2} \iint_{\Omega} (I_u^c - I_f^c)^2 dx dy$$

ובצורה דיפרנציאלית :

$$|\nabla I_u^c| = \sqrt{I_{u_x}^c{}^2 + I_{u_y}^c{}^2}; \quad \nabla = \left(\frac{\partial}{\partial x}, \frac{\partial}{\partial y} \right) \quad I_{u(i,j)}^{c(n+1)} = I_{u(i,j)}^{c(n)} - \Delta t \lambda (I_{u(i,j)}^{c(n)} - I_{f(i,j)}^c) + \Delta t \left(\nabla \cdot \left(\frac{\nabla I_{u(i,j)}^{c(n)}}{|\nabla I_{u(i,j)}^{c(n)}|} \right) \right)$$

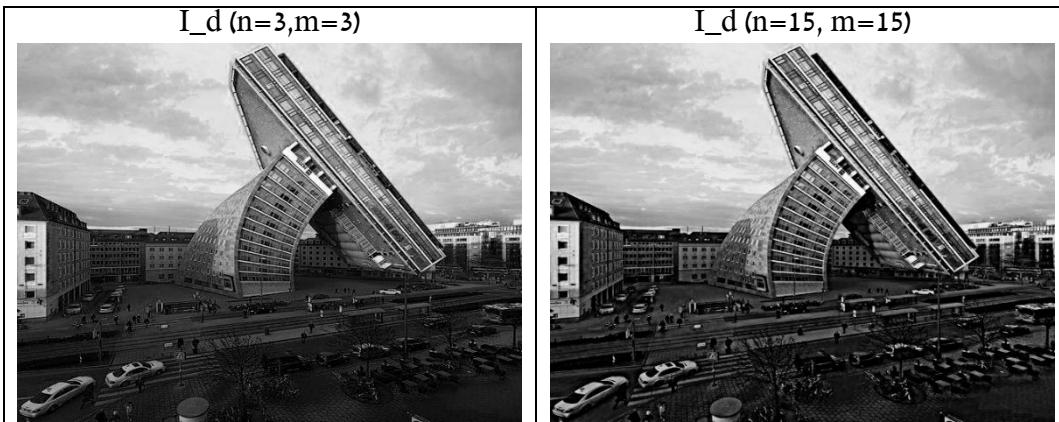
כאשר, $\lambda=100$ מייצג את מספר האיטרציות, ו- $\Delta t=0.25$ מייצג את קפיצה בזמן. λ – הינו פרמטר רגולרייזציה, ככל שערך קטן יותר כך התוצאות גדול יותר.

	V – channel after TV (I_u_V)	S – channel after TV (I_u_S)
$\lambda = 90$		
$\lambda = 0.05$		

למרות שרוב מידע התמונה נשמר בתהליך-TV-denoising, חלק מפרטי התמונה גם אובדים. לכן, יש לשפר את פרטי התמונה, המידע האפור והשונות של התמונה משמשים כדי להגדיר את פרמטרי טרנספורמציה של גמא כדי להציג את פרטי התמונה. הנוסחה היא כדלקמן:

$$b(x,y) = \frac{\sum_{m,n} (I_u^V(x,y) - N(x,y))^2}{m \cdot n}, \quad N(x,y) = \frac{\sum_{m,n} I_u^V(x,y)}{m \cdot n}, \quad I_d = I_u^V(x,y) \left(\frac{N(x,y) + b(x,y)}{I_u^V(x,y)} \right)$$

כאשר A ו- b הם הערך האפור הממוצע והשונות של האזור המקומי בגודל (m, n) של נקודות הפיקסל שבמרכזו (x,y) .



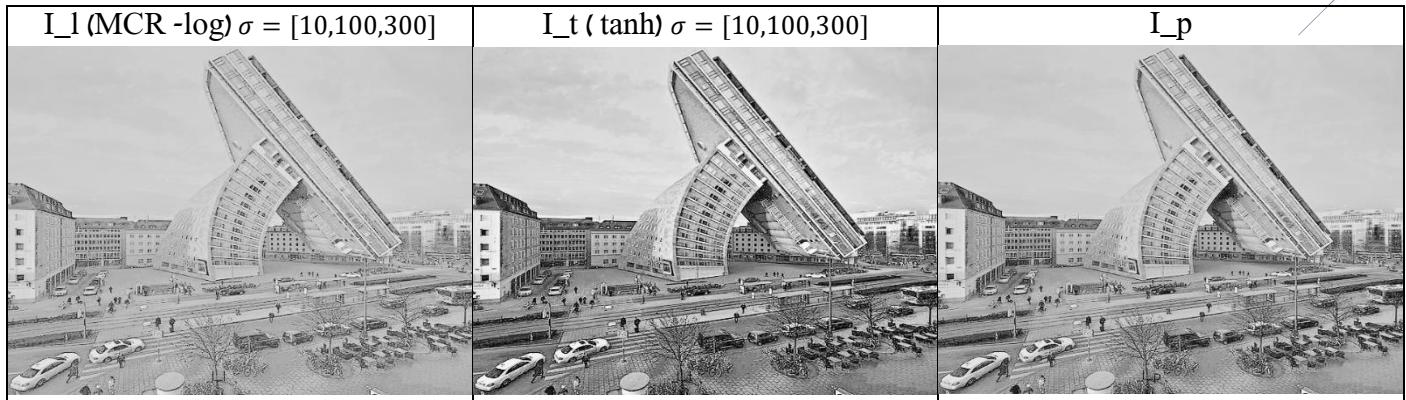
Double-Function Image Enhancement

כפי שהזכר לעיל, האלגוריתם MSR משתמש בפונקציית הגראון של גאוס המדגישה מידע מרחבית כדי להעריך את תמונה האירוע ומuttleם מידע הקצוות של התמונה, מה ששוביל להתרחשות של הילה בתמונה המשופרת במקור האור. ניתן לפטור בעיה זו ביעילות על ידי שימוש בסיכון מודרך שקובע את שניהם כדי להעריך את תמונה האירוע. ניתן למשתמש את השיפור של האזור הכהה וכןן על עכבר שייפור מוגזם של האזור הבRIGHT, אפקט השיפור בין שתי המעלות אינו ברור; אפקט השיפור של כל התמונה עומם, בעוד שהפונקציה הלוגריתמית משתנה מאוד לאחר טרנספורמציה הפוכה. לכן, מאמר זה מנצל את המאפיינים של שנייהם. פרמטרי ההיתוך מתוכננים בהתאם לבתיות האזור המקומי של התמונה כדי להשיג איזון בין שתי התמונות. הנוסחה מוצגת להלן:

$$I_p = \alpha I_l + \beta I_t \quad \alpha = \frac{\sum_{m,n} I_t}{\sum_{m,n} I_l}, \quad I_t = \sum_j^N \omega_j \left\{ \tanh \left(\frac{I_d(x,y)}{I_d(x,y) \otimes G_j(x,y)} \right) \right\}, \\ \alpha + \beta = 1$$

כאשר, I_l הינו שייפור בעזרת אלגוריתם MSR, I_t – הינו מושג שיפור של טנגנס היפרבולי.
 $G_j(x,y)$ – הינו גראון טשטוש עם סטיית תקן σ שונה.

لتמונה המתקבלת על ידי הפונקציה הלוגריתמית יש בהירות כללית גבוהה יותר, ואובדן רב יותר של פרטיים מקומיים, בעוד שלתמונה המתקבלת על ידי פונקציית הטנגנס ההיפרבולית יש בהירות כללית נמוכה יותר, ניגודיות נמוכה ומטושטשת. התמונה המתקבלת על ידי שילוב שתי הפונקציות יכולה לדכא שייפור מוגזם.

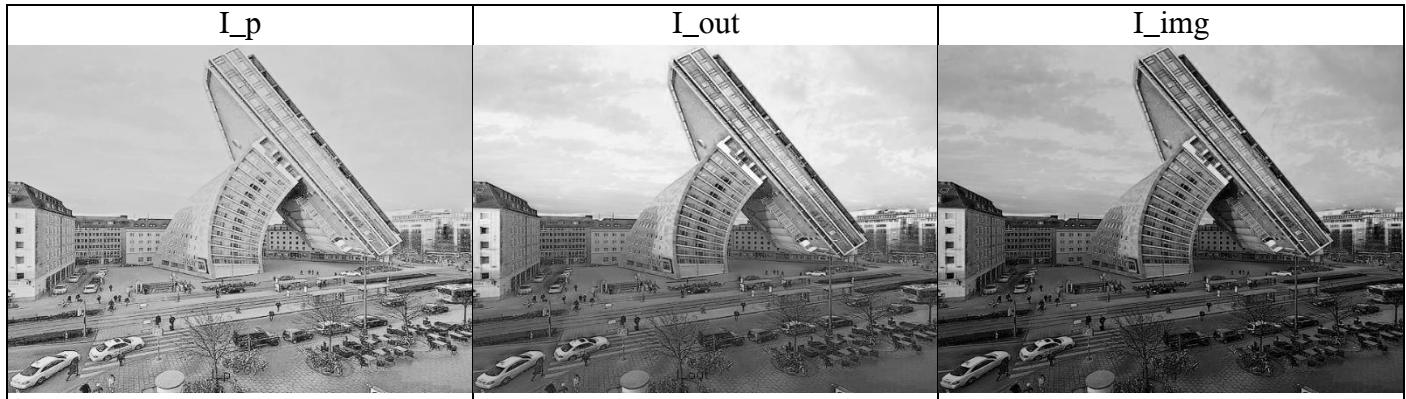


Three-Dimensional Gamma Correction

על מנת לפתור את בעיית "ערפל לבן" לעיל, סעיף זה משתמש בהמרת גמא כדי להתאים את התמונה המפוארת ולאחר מכן, על בסיס זה, לתקן את התמונה המשופרת. בהתחשב בבהירות ובמידע המפורט של התמונה, ערכי פרמטר הגמא נקבעים משלושה מימדים, כמוור קנה המיידה האפור, השונות והערך גרדיאנט של התמונה. הנוסחה היא כדלקמן:

$$\begin{aligned}
 C - \text{היינו הוויריאנס שמחושב} \\
 \text{אותו דבר כמו}: & \quad B(x, y) = \frac{\sum_{m,n} |\nabla I_d(x, y)|}{m \cdot n}, \quad I_{\text{out}} = I_d^{(\psi \cdot \exp(A) + \mu \cdot \exp(B) + \nu \cdot \exp(C))} \\
 b(x, y) = & \frac{\sum_{m,n} (I_u^V(x, y) - N(x, y))^2}{m \cdot n}, \quad A(x, y) = \frac{I_d(x, y)}{\max_{n \times m} I_d(x, y)}
 \end{aligned}$$

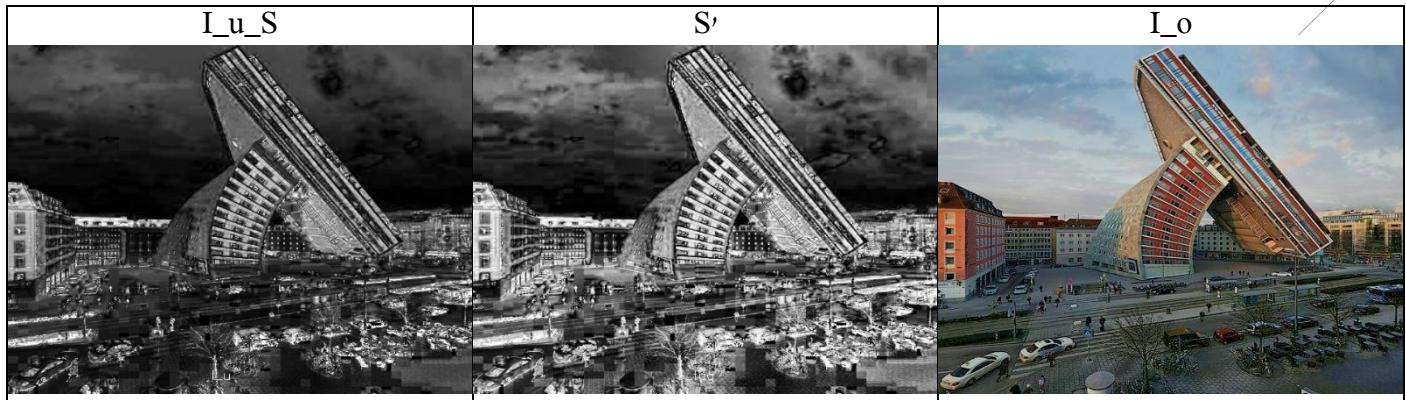
הניגודיות של התמונה המתוקנת משופרת משמעותית ובהירות הכללת של התמונה מתואמת.



Saturation Regulation

בתמונה בעלת עצמת האירה נמוכה, רווית התמונה באזורי הכהה נמוכה. הפיכה ישירה של תמונות הערוץ המעובדות לתמונה RGB תוביל לTOPFADE של "נקודה כהה" באזורי הכהה של התמונה. ניתן להקל על TOPFADE זו על ידי התאמת ערז הרויה של התמונה, והנוסחה מוצגת כדלקמן:

$$\text{כאשר } S_m \text{ הוא הערך הממוצע I באזור (m,n) שברeczy נקודה (i,j), } S_g \text{ הוא גרדיאנט של I בנק' (i,j)} \quad S' = \begin{cases} 1 + 0.8 \cdot \log \left(\frac{S_m}{I_u^S(i,j) + 0.5 \cdot S_g(i,j)} \right), & I_u^S(i, j) \leq \vartheta \\ \exp \left(\frac{S_m - I_u^S(i,j)}{2} \right), & \text{else,} \end{cases}$$

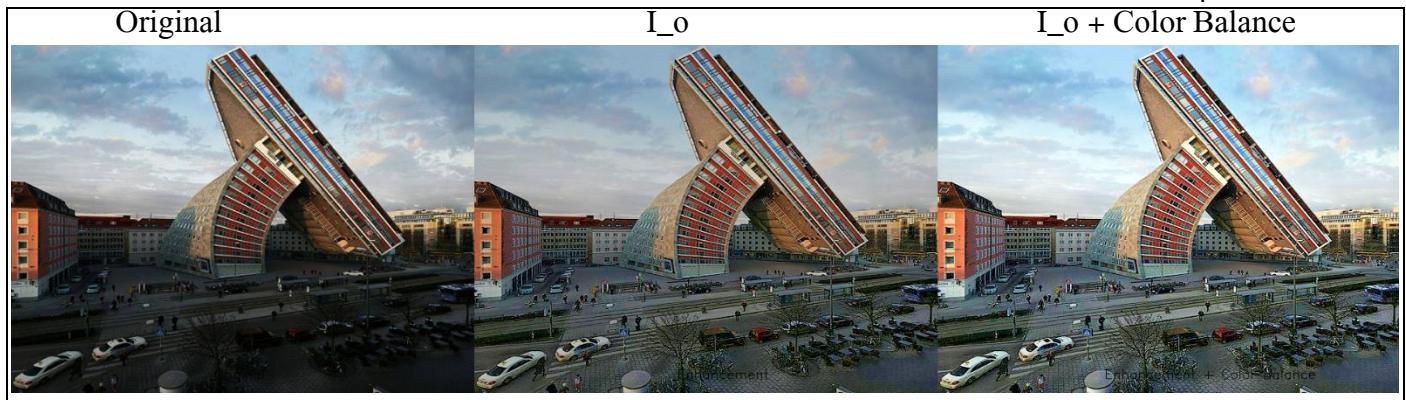


כדי לאמת את יעילות האלגוריתם, בחרנו כמה תמונות לניסויי השיפור; גודל התמונה הוא 480x640, אלגוריתמים להשוואה:

MSRCR, CLAHE, AHE (Adaptive Histogram Equalization), DFE (Proposed), DFE+CB
בנוספף לモצא של אלגוריתם DFE בוצע מתייחת ניגודיות התמונה באמצעות אלגוריתם איזון הצבע הפשטוט
bijouter עם אחוז חיתוך של 1% בשני הקצוטות. תיאור של אלגוריתם הינו במאמר הבא:

[Simplest Color Balance](#)

כתוצאה מתיקבלת:

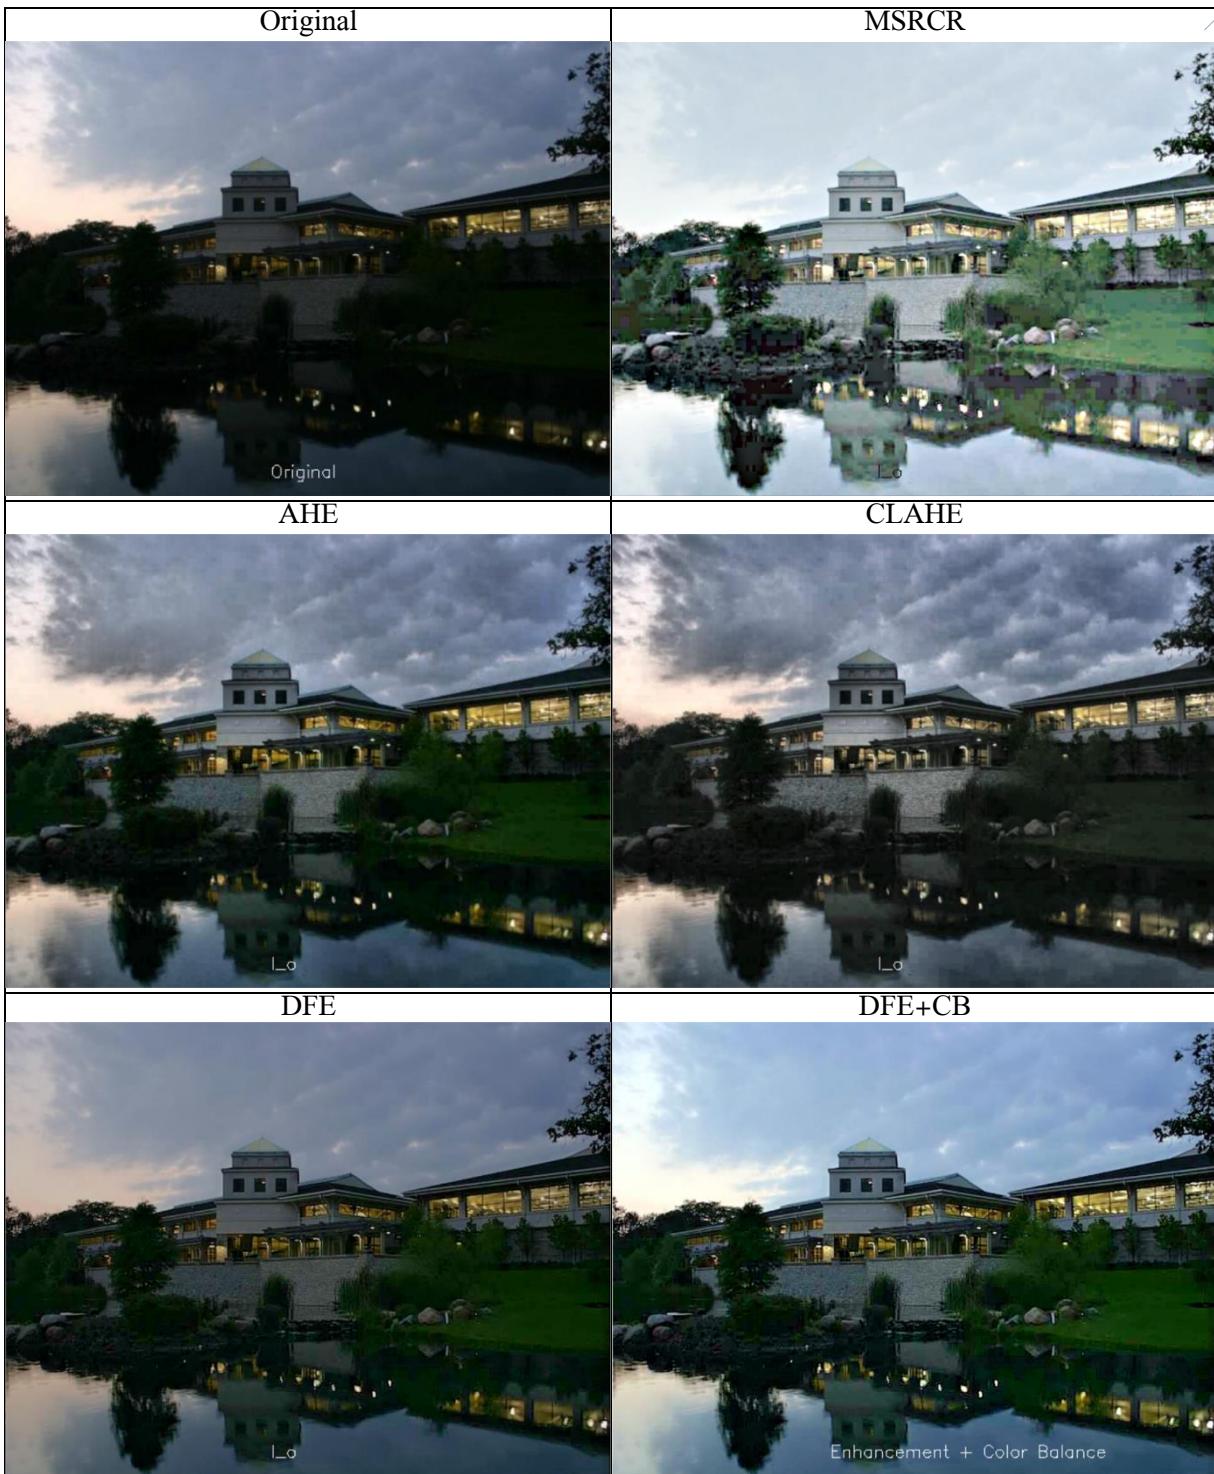


תוצאות

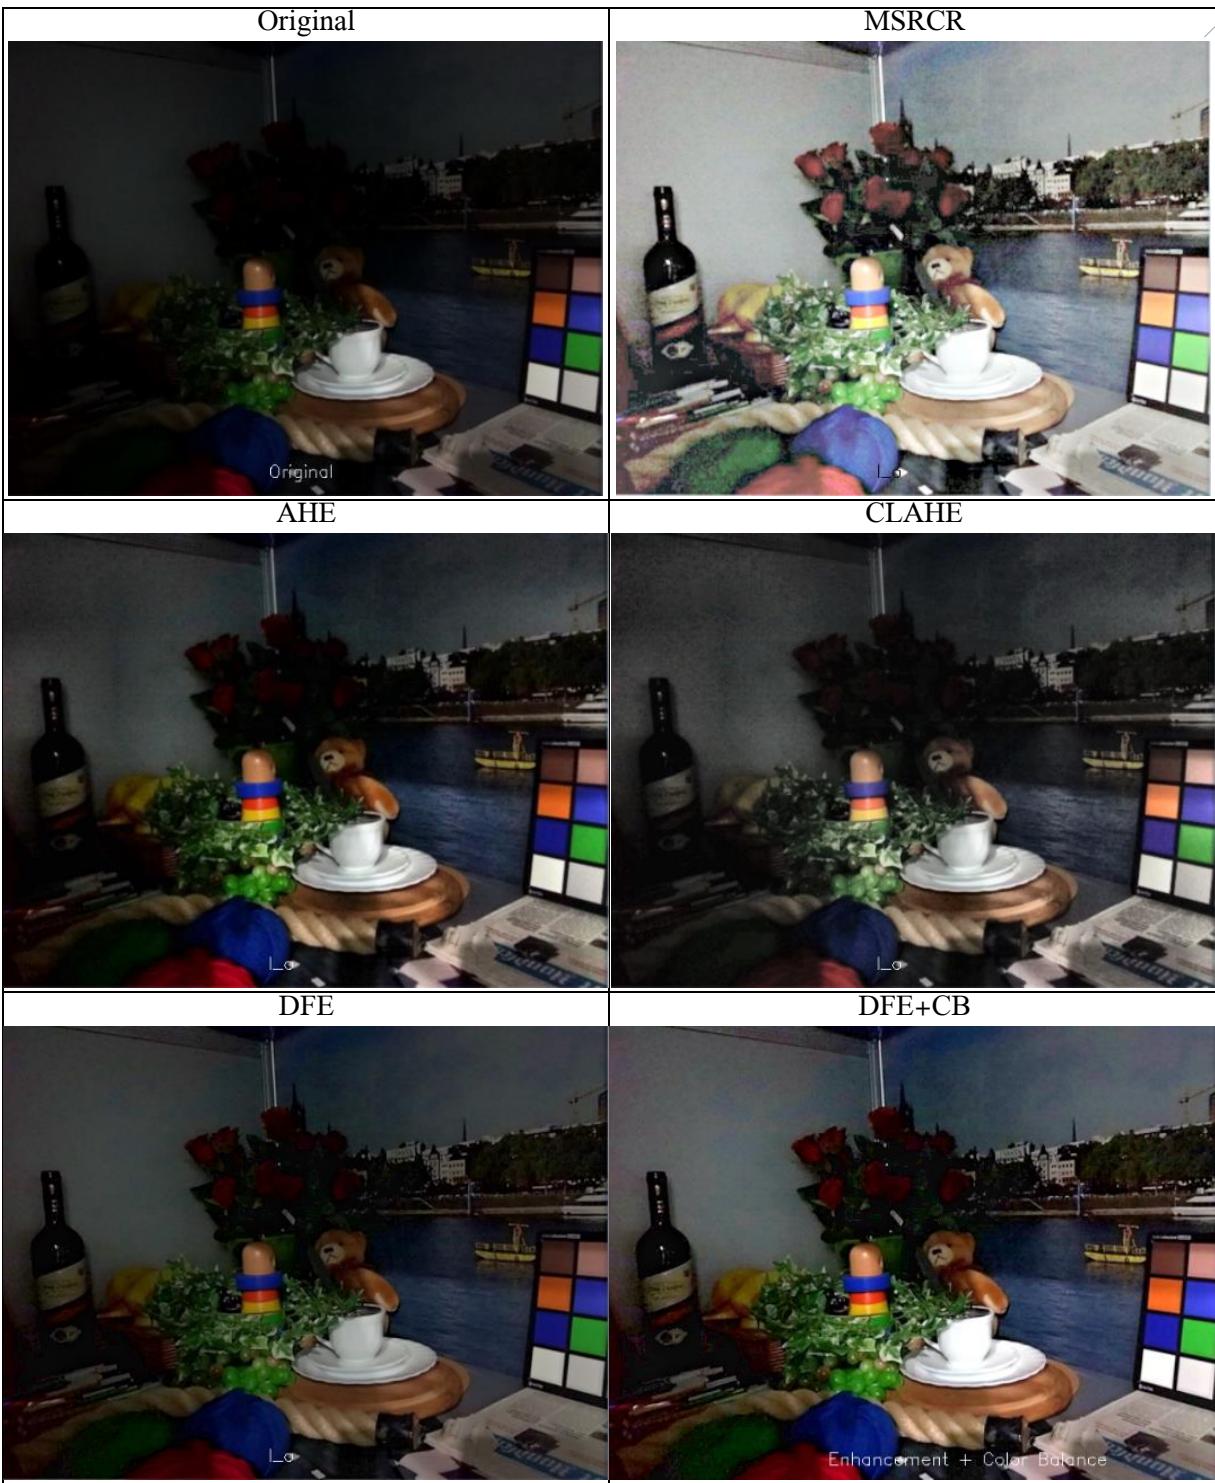
מטריקות לבחינה הימנו:

יחס אות לרעש מקסימי (PSNR) משמש למדידת הרעש של התמונה המשופרת, דמיון מבני (SSIM) משמש למדידת הדמיון המבני בין התמונה המשופרת לתמונה המקורי כדי לשפט את העיינות של התמונה. סטיית תקן (SD) משמשת כדי לשקוף את מידת הפיזור של פיקסלים ביחס לממוצע לאפין ניגודיות התמונה. אנטרופיה המידע (E) משמשת כדי לשקוף את עוצמת המידע בתמונה ולאפין את מורכבות התמונה.

- כל שהערכים של SD, SSIM, PSNR ו-Eו גבוהים יותר, כך אפקט השיפור/תיקון טוב יותר.



Model	PSNR	SSIM	SD	IE
MSRCR	8.8274	0.4743	71.088	7.5668
CLAHE	18.7077	0.7241	61.8372	7.4488
AHE	20.8266	0.8143	62.2678	7.428
(Proposed) DFE	22.2562	0.7969	55.9371	7.2383



Model	PSNR	SSIM	SD	IE
MSRCR	6.7682	0.2338	58.4677	7.6574
CLAHE	18.3605	0.6047	45.4709	6.7732
AHE	19.8661	0.7196	44.1037	6.8306
(Proposed) DFE	21.6438	0.6561	33.7318	6.6549



Model	PSNR	SSIM	SD	IE
MSRCR	10.6237	0.2913	51.746	7.58
CLAHE	19.2789	0.6353	49.1868	6.7995
AHE	22.3358	0.7462	45.8745	6.7893
(Proposed) DFE	21.9751	0.5809	38.5961	6.778



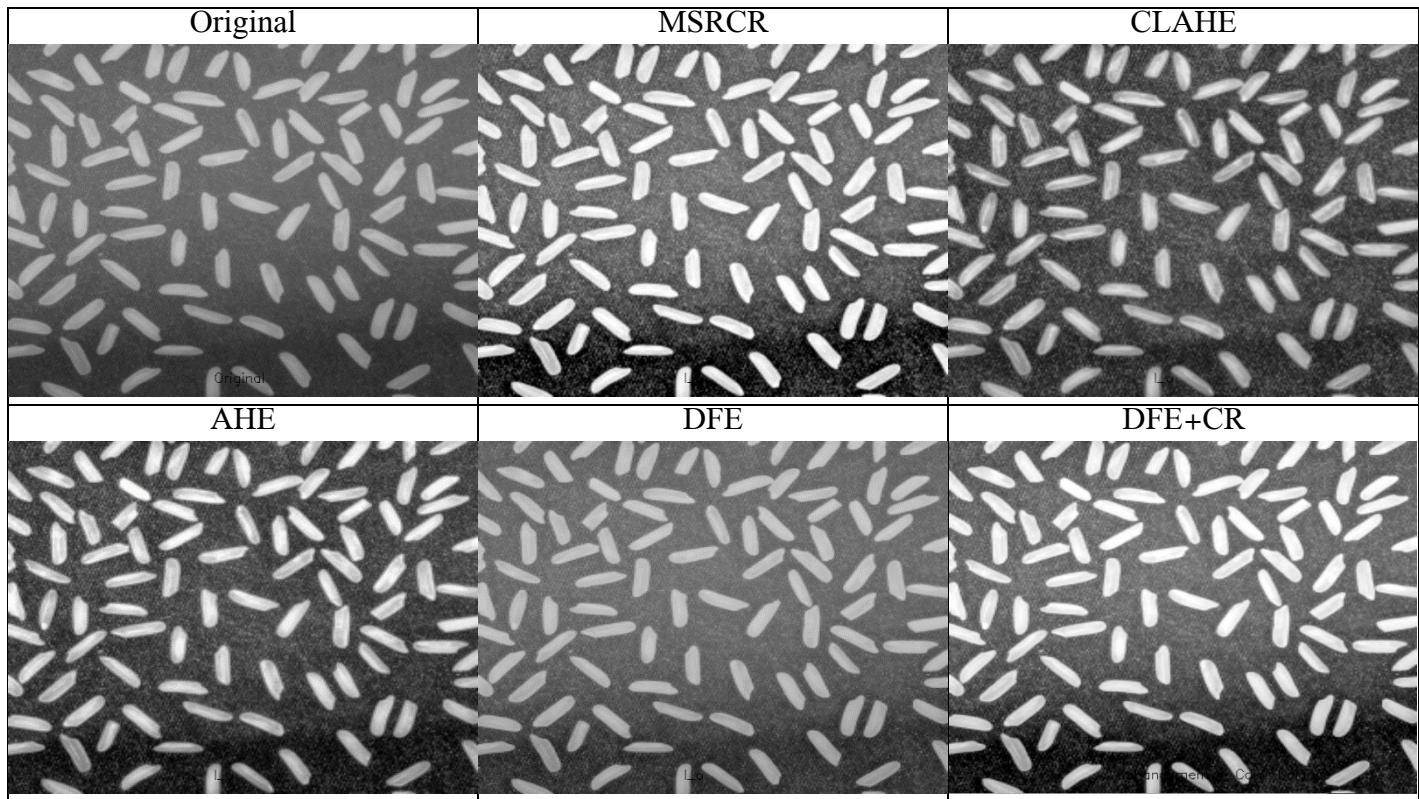
Model	PSNR	SSIM	SD	IE
MSRCR	9.8552	0.5621	59. 4269	7.3914
CLAHE	17.7935	0.7087	72.7262	7.7825
AHE	21.3203	0.8168	78.2544	7.6619
(Proposed) DFE	21.3572	0.8069	72.8551	7.3703



Model	PSNR	SSIM	SD	IE
MSRCR	10.0125	0.598	61.5688	7.1963
CLAHE	15.8441	0.669	64.2281	7.8122
AHE	17.6902	0.7426	64.8412	7.8785
(Proposed) DFE	20.5207	0.7773	63.2275	7.336



Model	PSNR	SSIM	SD	IE
MSRCR	7.4617	0.4107	62.4039	7.6914
CLAHE	18.2635	0.6579	52.4537	7.4172
AHE	20.9956	0.7648	54.3825	7.4782
(Proposed) DFE	21.0549	0.6851	51.1047	7.3812



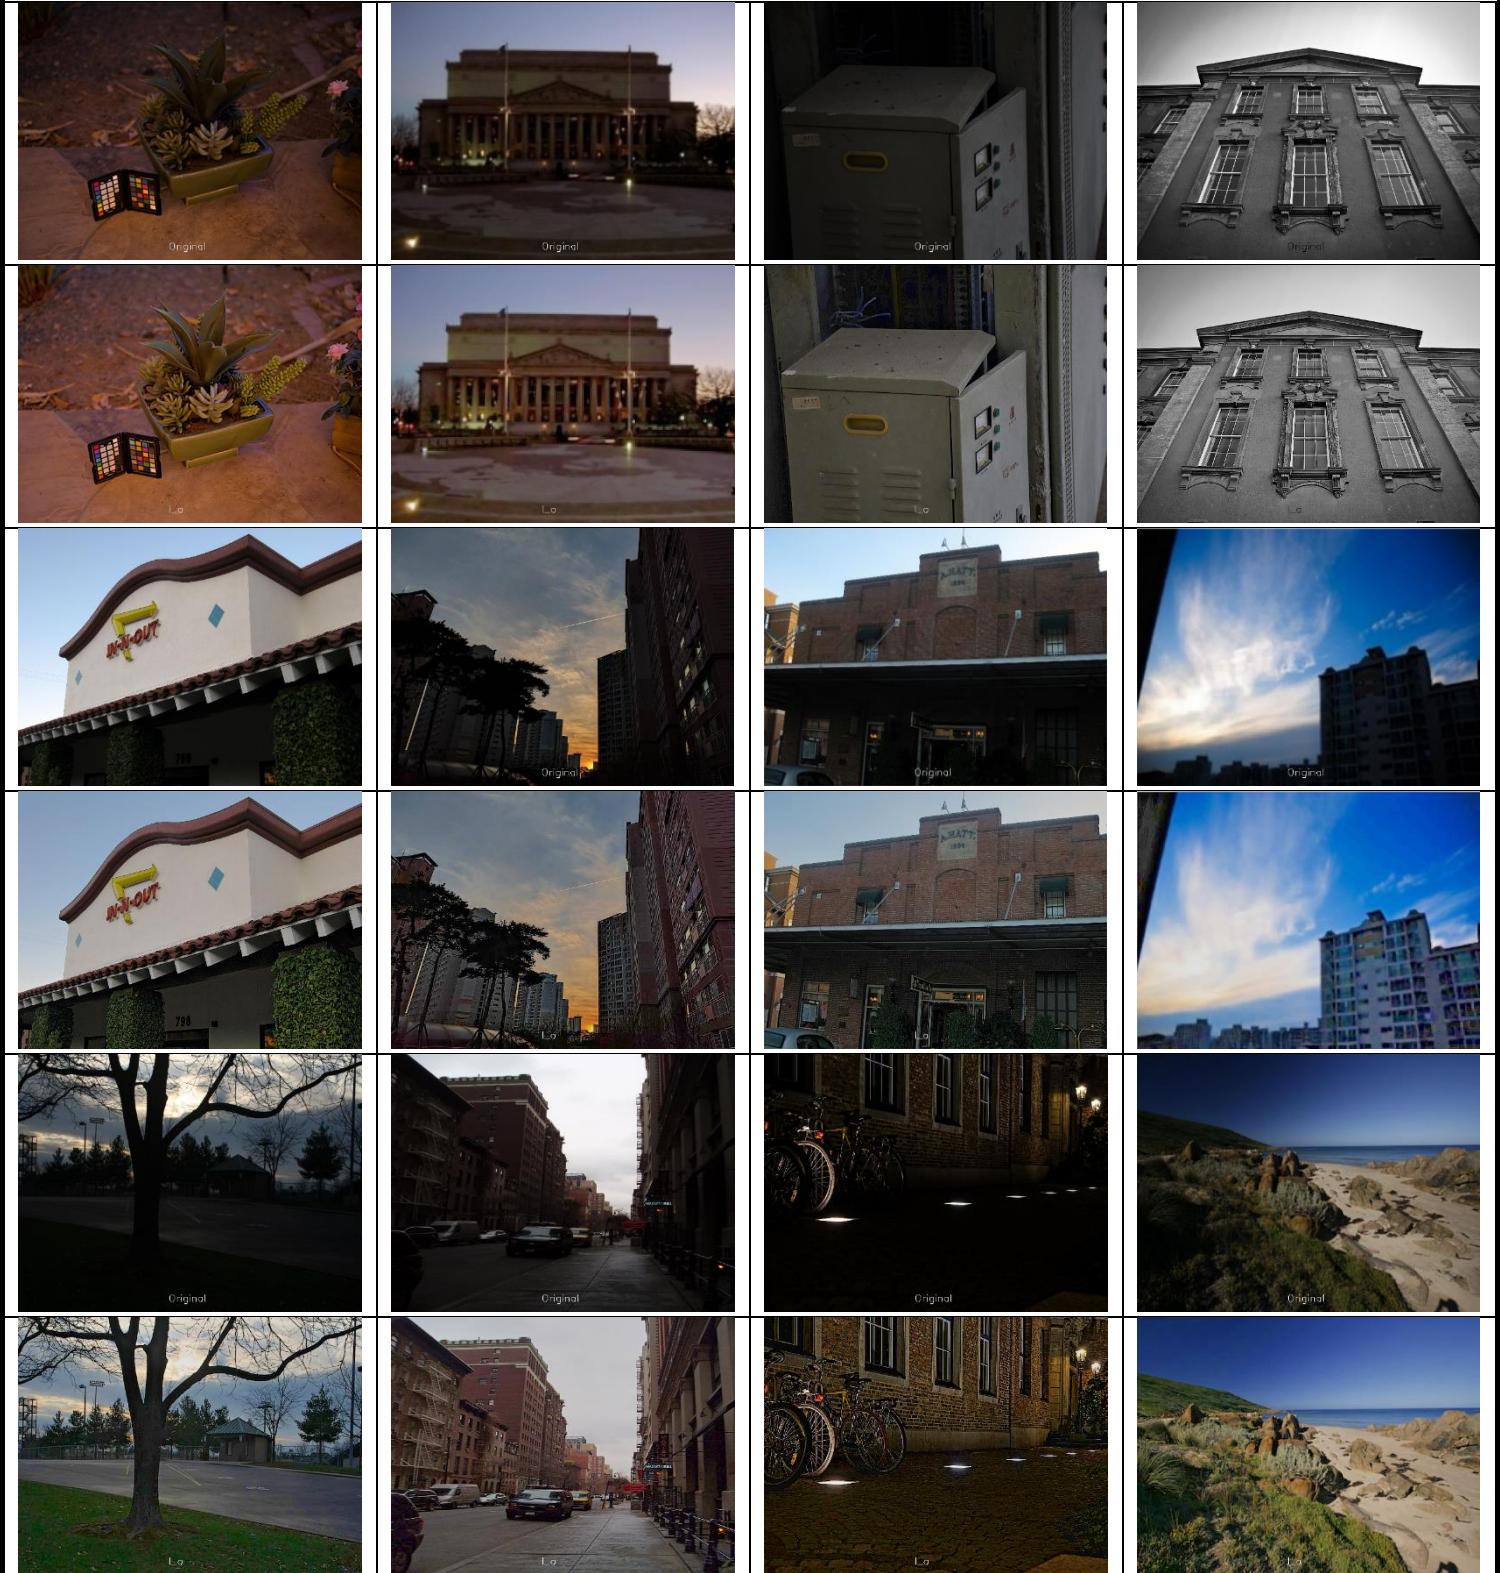
[1]

מסקנות:

מאמר זה הציע אלגוריתםיעיל לשיפור תמונה המסוגל להתגבר על הבעיות של הגברת רעש ושיפור מוגזם, בឋאליך של שיפור תמונה בתאורה נמוכה. עבודה זו מאמצת שיטת TV-Denoise ליעיבוד מקדים של תמונה, והטרנספורמציה הגמא האדפטיבית משמשת לשיפור פרטיו התמונה. פונקציית \tanh - \tanh ופונקציית הלוגריתם (MSR) מושולבות כדי להשיג את התמונה המשופרת המקדימה כדי למנוע שיפור תמונה מוגזם. טרנספורמציה גמא תלת ממדית משמשת כדי להתאים ולתקן את התמונה המשופרת. מהותוצאה הסובייקטיבית, נמצא שהתמונה המשופרת בוצרה היטב.

בנוסף אלגוריתם עובד פחות טוב על תמונה עם ערך אפור בלבד מאשר תמונה בעלי שלושה עורוצים.

עד תמונות •



הסבר על שימוש בעוג

ווע רשות בשפט פיתון

את GUI ניתן להפעיל בעזרת שני דרכי:

.1

בעזרת שימוש בקובץ Double-function enhancement algorithm.py יש לפתח את קובץ זה בסביבה העבודה של Visual Studio Code או PyCharm

יש לתקן ספריות הבאות (לערץ פקודות) :

```
pip install tk  
pip install numpy  
pip install matplotlib  
pip install scipy  
pip install opencv-python  
pip install scikit-image
```

2

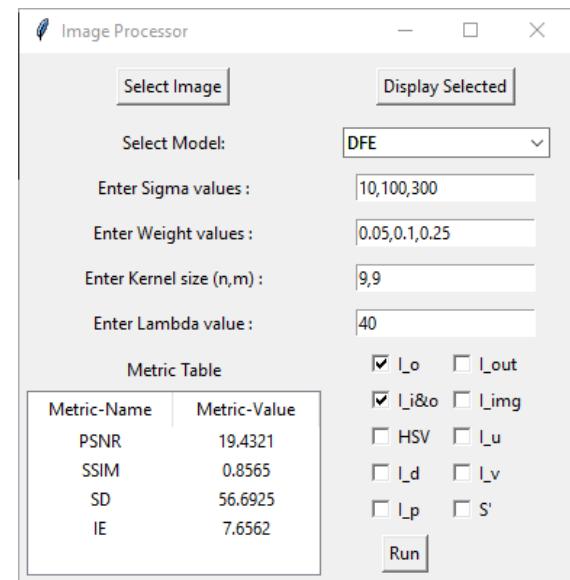
– Double Click Me To Run The App --.bat בעזרת הפעלת קובץ

*ראשית יש להוריד את תיקיה למחשב ולבצע Unzip

*לא נדרש להתקין ספריות

שימוש:

- Select Images – בחרה תמונות מתוק התייקה.
 - Display Selected – כפטור שיציג את תמונה שנבחרה
 - כדי להמשיך ולוחוץ על כפותורים אחרים קודם יש לסגור את חלון הפתוח, סגירת חלון אפשרית בשלושה דרכים: 1) לחיצה מקש ESC (2) בעורת עבר בלחיצה על X (3) בעורת לחיצה על מיקש ימין של עבר כבר כאשר סמן נמצא באזורי החלון פתוח.
 - Select model – בחירת אלגוריתם שיפור תמונה, לכל אלגוריות תינן אופציות עבור פרמטרים שונים.
 - TV – Denoise – פרמטר ל Lambda
 - Weight – פרמטרים ל גרעין gamma correction 3 dim
 - Sigma – פרמטרים ל גרעין טשטוש גאוסיאני
 - Kernel – גודל גרעין / חלו
 - Run – כפטור הרצתה.



- **כדי להמשיך וללחוץ על כפתורים אחרים קודם חלון הפתוח, סגירת חלון אפשרית בשולחה דרכיהם: 1) לחיצת מקש ESC (2) בעזרת עכבר בלחיצה על X (3) בעזרת לחיצה על מקש ימין של עכבר כאשר סמן נמצא באזור החילון פתוח.

• **הקוד נמצא ב** Git

Discrete Cosine Transform – based Image Fusion

היתוך תמונה באמצעות טכניקת המרת קוסינוס בדידה (MDCT) מרובת רזולוציות נבנה ונבדק. הביצועים של גישה זו מושווים לאלו של טכניקת היתוך תמונה ידועה המבוססת על wavelets. ביצוע היתוך תמונה MDCT זהה בערך ל-wavelets. זה מאד פשוט מבחינה חישובית ועשי להתאים ליישומים בזמן אמת.

מבוא

היתוך תמונה מרובה-חישוניים (MIF) היא טכניקה להגדלת הרזולוציה המרחבית של תמונות מרובי-חישונים עם פרטימס נמוכים תוך שמירה על המידע הספקטרלי שלhnן על-ידי שילוב של שתי תמונות או יותר. MIF הופיע לאחרונה כנשא מחקר חדש וمبתייח לעיבוד תמונות. צבא, חישה מרוחק, ראיית מכונה, רובוטיקה, מעקב, מרכיבים וריאיה משופרות והדמיה רפואיים הם חלק מהענפים שנחנים מ-MIF.

MIF מנסה להתמודד עם האתגר של מיזוג תוכן המידע של תמונות רבות (או שנאספו מישיות חיישן הדמיה שונות) שצולמו מאותה סצנה על מנת להשיג תמונה משולבת המשלבת את המידע הטוב ביותר מהתמונות המקור השונות.

כתוצאה לכך, התמונה הממזוגת תהיה עדיפה על כל אחת מתמונות המקור. MIF יכול להתבצע בשלוש רמות שונות, בהתאם לשלב המיזוג: רמת פיקסל, רמת תכונה ורמות החלטה. במחקר זה, מຕאר MIF מבוסס רמות פיקסל, המתאר תהליך היוצר תמונה ממוגנת אחת עם תיאור מדויק יותר מתמונות המקור הבודדות.

ה-MIF הפשט ביותר הוא לנקה את הממוחע של פיקסלים של תמונות המקור ברמת האפור. שיטה זו תגרום לתוצאות לא רצויות שונות וניגודיות נמוכה יותר בתמונה הממזוגת. טרנספורמציות (התמרת) רבות כגון wavelet, פירמידות, תדר מרחבי, עיבוד אוטומטי סטטיסטי ותאורית הקבוצות המתווששות הוצעו כדי לטפל בבעיות אלו. התמרת wavelet מרובות רזולוציות עשויה להיות שימושית עבור לוקלייזציה הן בתחום המרחבי והן בתחום התדר. טרנספורמציה(התמרת) wavelet תציג מידע כיווני ברמות פירוק ומידע ייחודי ברזולוציות שונות.

טרנספורמציה(התמרת) של קוסינוס בדיד רב-רזולוציה (MDCT) משמשת במחקר זה כדי למוג את תמונות המקור בעלות פוקוס חלק. אחד הקריטריונים הבסיסיים ליישום טכניקות היתוך על תמונות הוא רישום תמונה, כמו למשל המידע בתמונות המקור חייב להיות מיושר ורשום כראוי לפני היתוך.

התמרת קוסינוס בדידה

התמרת קוסינוס בדידה (DCT) היא טרנספורמציה חשובה בעיבוד תמונה. מקדמי DCT גדולים מרכזים באזור התדר נמוך; לפיכך, ידוע כבעל תכונות דחיסה אנרגטית מצוינות. התמרת הקוסינוס הבודד D₁ הופך את (n, k) ל- $X(k)$ באורך N.

$$X(0) = \sqrt{\frac{1}{N}} \sum_{n=0}^{N-1} x(n), \quad k=0$$

המשוואה (1) הופכת למקדם

הטרנספורמציה הראשון שהוא הממוחע של כל הדגימות ברכף והוא ידוע כמקדם DC, ומקדמי AC. טרנספורמציה אחריהם ידועים כמקדמי AC.

טרנספורמציה הקוסינוס ההיפוכה מוגדרת כ:

$$x(n) = \sum_{k=0}^{N-1} \alpha(k) X(k) \cos\left(\frac{\pi(2n+1)k}{2N}\right), \quad 0 \leq n \leq N-1 \quad (3)$$

$$X(k) = \alpha(k) \sum_{n=0}^{N-1} x(n) \cos\left(\frac{\pi(2n+1)k}{2N}\right), \quad 0 \leq k \leq N-1 \quad (1)$$

$$\text{where } \alpha(k) = \begin{cases} \sqrt{\frac{1}{N}} & k = 0 \\ \sqrt{\frac{2}{N}} & k \neq 0 \end{cases} \quad (2)$$

כאשר $\cos\left(\frac{\pi(2n+1)k}{2N}\right)$ הינה פונק' גרעין אמיתי וDISKRETIT.

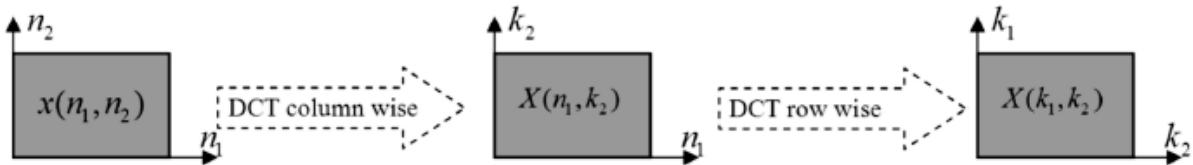
ה-DCT 2 הוא הרחבה ישירה של 1D DCT. המרת הקוסינוס הבודד הדו-ממדי $X(k_1, k_2)$ של תמונה מוגדר כ:

$$x(n_1, n_2) = \sum_{k_1=0}^{N_1-1} \sum_{k_2=0}^{N_2-1} \alpha(k_1) \alpha(k_2) X(k_1, k_2) \cos\left(\frac{\pi(2n_1+1)k_1}{2N_1}\right) \cos\left(\frac{\pi(2n_2+1)k_2}{2N_2}\right), \quad 0 \leq n_1 \leq N_1-1, \quad 0 \leq n_2 \leq N_2-1 \quad (5)$$

והתמרה הפוכה:

$$X(k_1, k_2) = \alpha(k_1) \alpha(k_2) \sum_{n_1=0}^{N_1-1} \sum_{n_2=0}^{N_2-1} x(n_1, n_2) \cos\left(\frac{\pi(2n_1+1)k_1}{2N_1}\right) \cos\left(\frac{\pi(2n_2+1)k_2}{2N_2}\right), \quad 0 \leq k_1 \leq N_1-1, \quad 0 \leq k_2 \leq N_2-1 \quad (4)$$

וגם IDCT זה טרנספורמציות אשר ניתנות להפרדה, היתרונו של תכונה זו היא חישוב 2D DCT או IDCT ניתן לבצע שני שלבים על ידי 1D IDCT או 1D DCT על עמודות ולאחר מכן על שורות של תמונה (n1,n2). כפי שמצוג באירור 1.



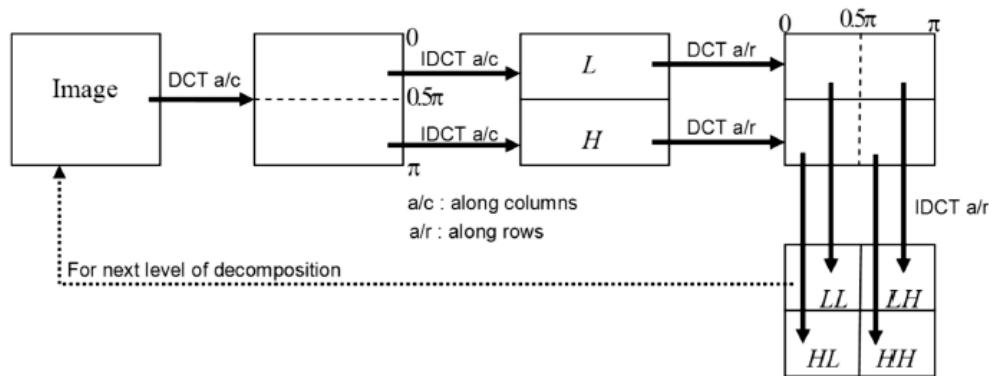
איור מס 1 ביצוע התמרת קוסינוס בדידה דו ממדית בעזרת תכונת ההפרדה

התמרת קוסינוס בדידה רב רזולוציה

טרנספורמציה קוסינוס מרובת רזולוציה דיסקרטית (MDCT) היא טכניקת עיבוד אותן הדומה להתמורות wavelets אשר מסנן את האות בנפרד על ידי מסני תגובה תדר סופית (FIR) במעבר נמוך ובמעבר גבוה, ואז הפלט של כל מסנן מופחת (הורדת צב דגימה) בפקטור של שניים כדי להשיג את רמת הפירוק הראשונה. כדי להשיג את רמת הפירוק השנייה. ניתן לחזור על תהליך זה כדי להשיג רמות אחרות של פירוק.

ה-MDCT מחליף את מסני FIR ב-(DCT, התמונה. כדי לבצע MDCT, מחליב את התדר על ידי יישום DCT באופן נטונות (0 עד $\pi/2$) נטונות עבורת פירוק בתחום התדר על ידי יישום DCT באופן גסומה. מחלוקת הנקודות הראשונות (0 עד $\pi/2$) נטונות ל-IDCT לקבלת את התמונה שעברה דרך מסנן נמוכים L, ומחלוקת השניה (0 עד π) נטונות ל-IDCT לקבלת את התמונה שעברה דרך מסנן גבוהים H. התמונה שעברה דרך מסנן נמוכים L עבורת טרנספורמציה בתחום התדר על ידי יישום DCT בזוירה של שורה. מחלוקת הנקודות הראשונות (באופן השורה) נטונות ל-IDCT כדי לקבל את התמונה LL שהועברה דרך מסנן גבוהים LH. התמונה שעברה דרך מסנן גבוהים H עבורת לקבלת את התמונה המועברת דרך מסנן גבוהים LH. התמונה שעברה דרך מסנן גבוהים H עבורת טרנספורמציה בתחום התדר על ידי יישום DCT באופן שורה. מחלוקת הנקודות הראשונות (באופן השורה) נטונות ל-IDCT ההפוך כדי לקבל את התמונה HL שהועברה דרך מסנן גבוהים HL, ומחלוקת נקודות הנותרות נטונות ל-IDCT לקבלת את התמונה המועברת דרך מסנן גבוהים HH.

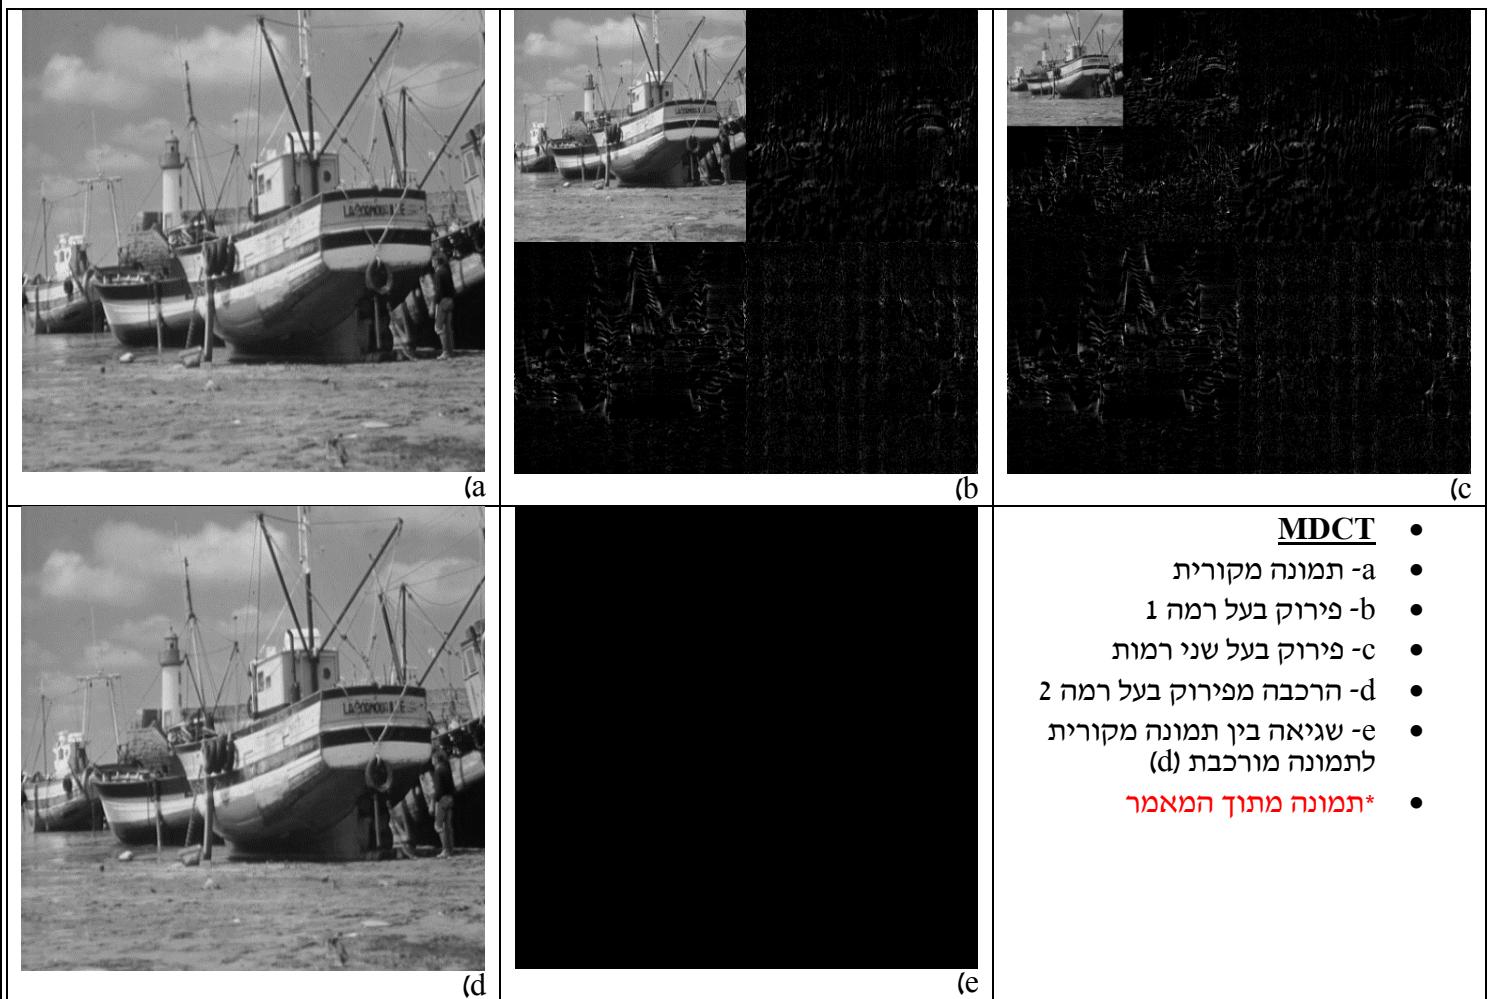
ה-LL מכיל את מידע התמונה הממוצע התואם לפס התדרים הנמוכים של הפירוק הרב-סקאלי. הוא מייצג את הגרסה המוחלקת והתדמית של תמונה המקור ויכול להיחשך כקירוב של תמונה המקור(Approximations). התמונות LH, HL ו-HH הן תת-תמונות מפורחות המכילות מידע כיווני (אופקי, אנכי ואלכסוני) של תמונה המקור עקב כיוון מרחביים(Details). ניתן להשיג ריבוי רזולוציה על ידי יישום רקורסיבי של אותו אלגוריתם על מקדמי המעבר הנמוכים (LL) מהפירוק הקודם. את אלגוריתם ניתן לראות באירור 2.



איור מס 2 פירוק רב רזולוציה בעזרת התמרת קוסינוס בדידה DCT

כעת אנו נציג את פירוק רב שלבי של התמונות (מתוך המאמר ומה שצולם בנוסך) בעזרת DCT וWavelet.

MDCT (Multilevel Discrete Cosine Transform)

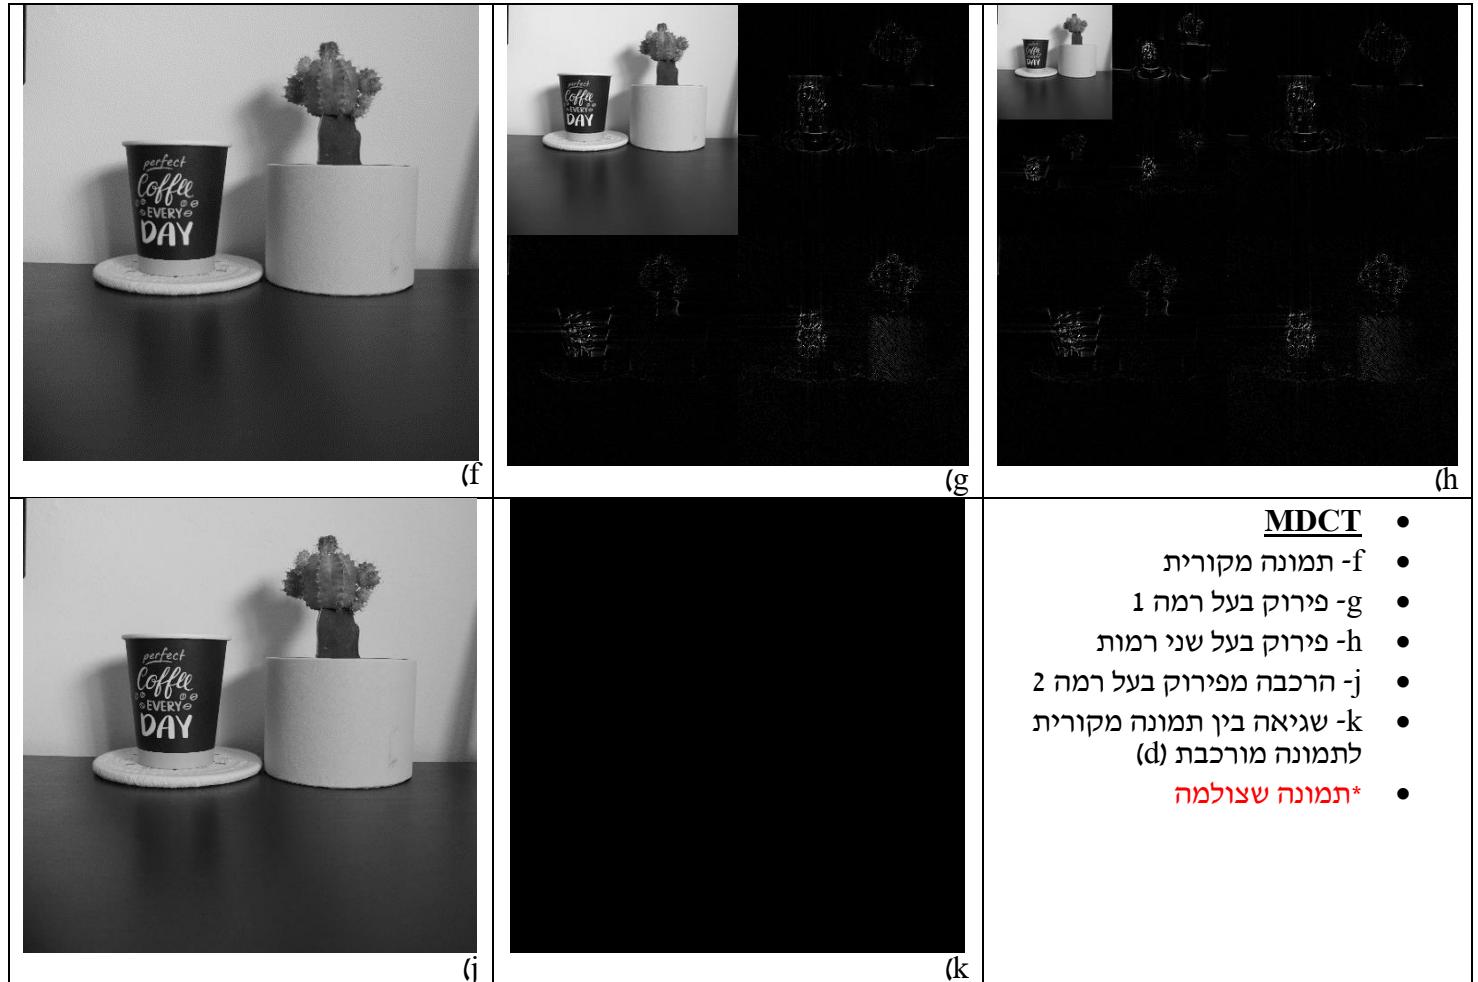


MDCT

- a- תמונה מקורית
- b- פירוק בעל רמה 1
- c- פירוק בעל שני רמות
- d- הרכבה מפירוק בעל רמה 2
- e- שגיאת בין תמונה מקורית לתמונה מורכבת (d)

*תמונה מתוך המאמר

-
-
-
-
-
-
-
-



MDCT

- f- תמונה מקורית
- g- פירוק בעל רמה 1
- h- פירוק בעל שני רמות
- j- הרכבה מפירוק בעל רמה 2
- k- שגיאת בין תמונה מקורית לתמונה מורכבת (d)

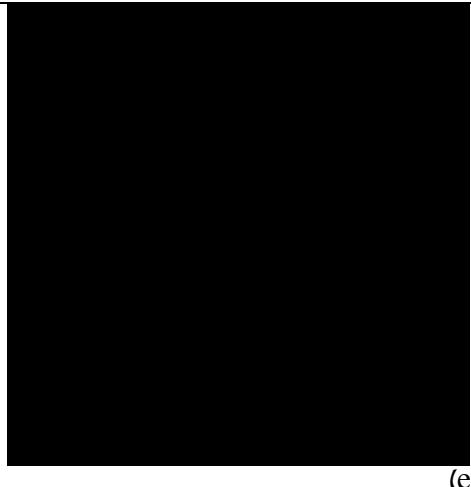
*תמונה צולמה

MDWT (Multilevel Discrete Wavelet Transform)



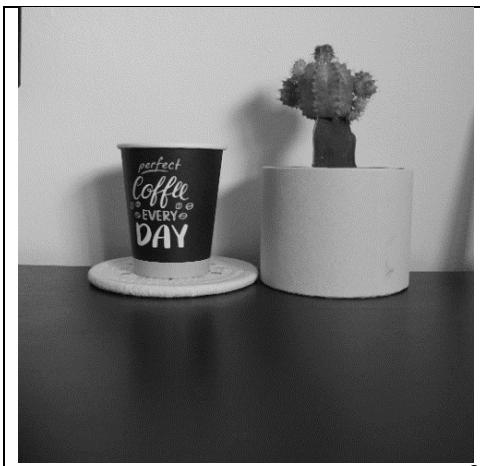


(d)



(e)

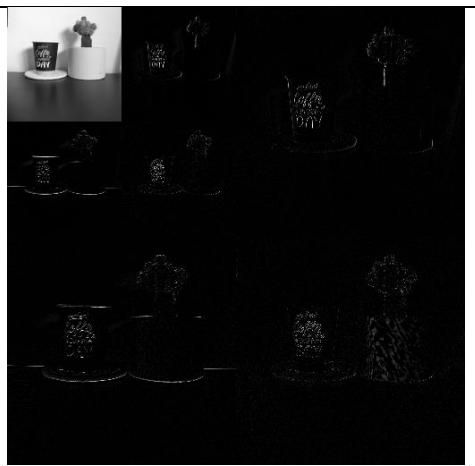
MDWT
a- תמונה מקורית
b- פירוק בעל רמה 1
c- פירוק בעל שני רמות
d- הרכבה מפירוק בעל רמה 2
e- שגיאה בין תמונה מקורית לתמונה מורכבת (d)



(f)



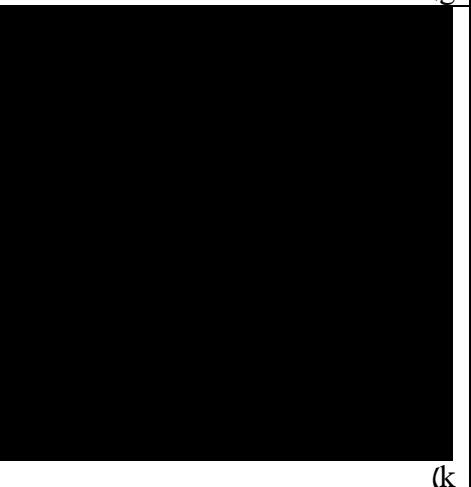
(g)



(h)



(j)



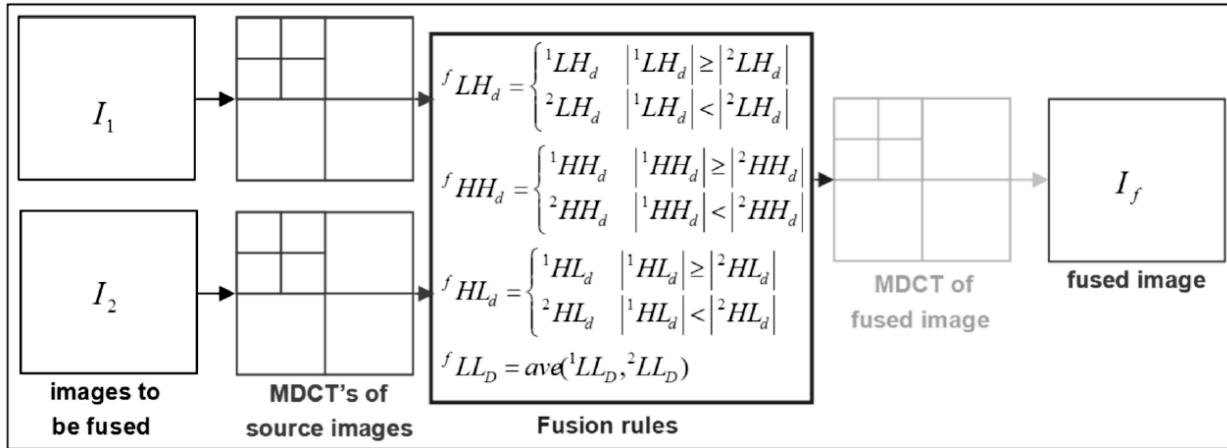
(k)

MDWT
f- תמונה מקורית
g- פירוק בעל רמה 1
h- פירוק בעל שני רמות
j- הרכבה מפירוק בעל רמה 2
k- שגיאה בין תמונה מקורית לתמונה מורכבת (d)

בשני התמונות שגיאה מרבית בין תמונה מקורית לתמונה שעברה פירוק והרכבה , בסדר גודל של $.10^{-13}$

היתוך

הדיagrammatic הסכמתית של היתוך תמונות על בסיס הפיקסל מבודס MDCT מוצגת באירור 3. נשים לב שהשינוי של האלגוריתם הנוכחי הוא השימוש ב-MDCT במקום Wavelets או פירמידות. התמונות להיתוך I₁ ו-I₂ מפורקות ל-D רמות באמצעות MDCT.



אייר מס 3 הדיאגרמה הסכמתית עבור היתוך תמונות ברמת פיקסלים מבוססת MDCT

$$I_1 \rightarrow \left\{ {}^1 LL_D, \left\{ {}^1 LH_d, {}^1 HH_d, {}^1 HL_d \right\}_{d=1,2,\dots,D} \right\}$$

$$I_2 \rightarrow \left\{ {}^2 LL_D, \left\{ {}^2 LH_d, {}^2 HH_d, {}^2 HL_d \right\}_{d=1,2,\dots,D} \right\}.$$

בכל רמת פירוק ($D = 1, 2, \dots, d$), כל היתוך יהיה

בחירתו הערך המוחלט הגדול ביותר של מקדמי הפרטים (Details), מכון שהמקדים ה"פרטים" מתאימים לשינויי בהירות חדים יותר בתמונות כמו קצוזות וגבולות אובייקט וכו'. מקדים אלה נעים סבב האפס. בrama הגסה ביותר ($D=d$), כל היתוך לוקח את המוצע של מקדי ה"קירוב" (Approximations) של MDCT שכן מקדי הקירוב הם גסים יותר הרמה היא הגרסה המוחלטת ותת הדגימה של התמונה המקורית. לאחר היתוך מושבע תהליך הרכבה ליצור תמונה סופית אשר נמצאת בפוקוס מלא.

הערכת ביצועים

עם תמונה יhos

כאשר תמונה יhos זמינה, הביצועים של אלגוריתמי היתוך תמונה ניתן להעריך באמצעות המדדים הבאים:

1. Percentage fit error (PFE)

למעשה זאת שגיאה ייחסת כאשר, הנורמה היא האופרטור לחישוב הערך הסינגולרי הגדול ביותר. מחושב כנורמה של ההבדל בין הפיקסלים של תמונה יhos ותמונה לאחר היתוך, חלקי נורמה של תמונה יhos.

יהיה אפס מתי גם תמונות היחסות וגם תמונות מתמצגות דומות לחלוטין, יחס שגיאה תגדל כאשר התמונה המmozגות שונה מתמונה היחסות.

2. Peak signal to noise ratio (PSNR)

כאשר L הוא מספר רמות האפור בתמונה. הערך של המטריקה תהיה בעלת ערך גבוה כאשר היתוך ותמונה יhos דומות. ערך גבוה יותר מרמז על היתוך טוב יותר.

$$PSNR = 20 \log_{10} \left(\frac{L^2}{\frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N (I_r(i,j) - I_f(i,j))^2} \right)$$

יש טעות אמרת להיות \log_{10} , אם משתמשים ב \log נדרש להוציא את חזקה 2 מתוך \log . •

$$SSIM = \frac{(2\mu_{I_r}\mu_{I_f} + C_1)(2\sigma_{I_rI_f} + C_2)}{(\mu_{I_r}^2 + \mu_{I_f}^2 + C_1)(\sigma_{I_r}^2 + \sigma_{I_f}^2 + C_2)}$$

3. Measure of structural similarity (SSIM). אוטות של תמונות טבעיות יהיו מובנים מאד והפיקסלים שלהם חושפים תלות חזקה. תלות זו ישאו מידע חיוני על מבנה האובייקט. מטריקה זו משווה תכניות מקומיות של עצמות פיקסלים שעברו נורמליזציה עבור בהירות וניגודיות. אני בחרתי לחתך חלון בגודל של 11×11 לחישוב ולאחר מכן מיצעו לקבלת ערך בודד.

כאשר :

$$\sigma_{I_r}^2 = \frac{1}{MN-1} \sum_{i=1}^M \sum_{j=1}^N (I_r(i,j) - \mu_{I_r})^2 \quad \mu_{I_f} = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N I_f(i,j) \quad \mu_{I_r} = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N I_r(i,j)$$

$$\sigma_{I_f}^2 = \frac{1}{MN-1} \sum_{i=1}^M \sum_{j=1}^N (I_f(i,j) - \mu_{I_f})^2 \quad \sigma_{I_rI_f} = \frac{1}{MN-1} \sum_{i=1}^M \sum_{j=1}^N (I_r(i,j) - \mu_{I_r})(I_f(i,j) - \mu_{I_f})$$

לא תמונה יחש כאשר תמונה יחש אינה זמינה, ניתן להשתמש במדדים הבאים כדי לבדוק את הביצועים של האלגוריתמים.

1. Standard deviation (SD)

σ היא היסטוגרמה המנורמלת של תמונה ממוגנת. ידוע שטיטיתת תקן מרכיבת חלקיקי אותן ורעש. מגד זה יהיה קטן יותר בהיעדר רעש. הוא מודד את הניגודיות בתמונה הממוגנת. לתמונה עם ניגודיות גבוהה תהיה סטיית תקן גבוהה.

2. Cross entropy (CE)

אנטרופיה צולבת כוללת של תמונות המקור I_1, I_2 , והתמונה ממוגנת היא :

$$CE(I_1; I_f) = \sum_{i=0}^L h_{I_1}(i) \log \left(\frac{h_{I_1}(i)}{h_{I_f}(i)} \right) \quad CE(I_2; I_f) = \sum_{i=0}^L h_{I_2}(i) \log \left(\frac{h_{I_2}(i)}{h_{I_f}(i)} \right) \quad CE(I_1, I_2; I_f) = \frac{CE(I_1; I_f) + CE(I_2; I_f)}{2}$$

3. Spatial frequency (SF)

קריטריון תדר מרחב

$$SF = \sqrt{RF^2 + CF^2}$$

תדרי השורה

$$RF = \sqrt{\frac{1}{MN} \sum_{x=1}^M \sum_{y=2}^N [I_f(x,y) - I_f(x,y-1)]^2}$$

תדרי عمودה

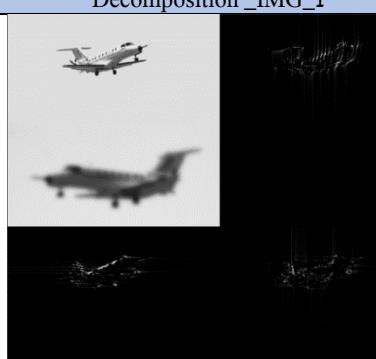
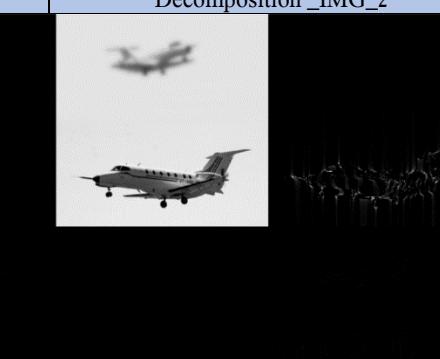
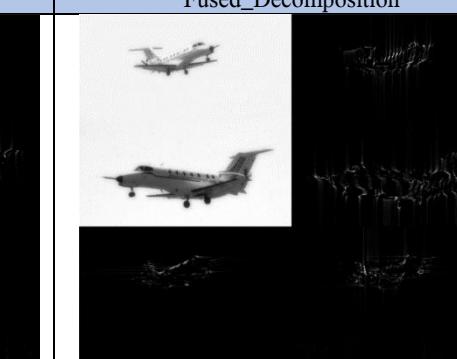
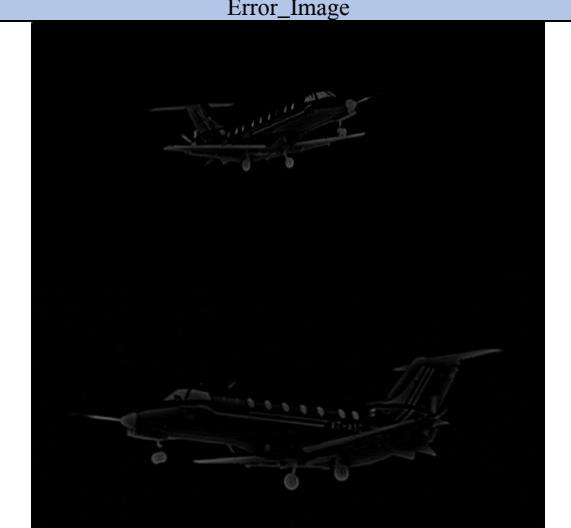
$$CF = \sqrt{\frac{1}{MN} \sum_{y=1}^N \sum_{x=2}^M [I_f(x,y) - I_f(x-1,y)]^2}$$

תדרות זו בתחום המרחבי מצינית את רמת הפעולות הכוללות בתמונה הממוגנת. (y, x) הוא אינדקס הפיקסלים.

פתרונות

התוצאות הבאות הן עברו תמונה ממאמר עם תמונה ייחוס (תהייה שונה במטריקות ממה שמוצאים במאמר מכוון שלא מצאתי תמונות אלו באינטרנט וביצוע צילום מסך) ובוסף תמונות נוספות שצולמו עם מוקד f=2.8.

חשוב לציין שיש חשיבות רבה לתמונות אשר נלקחו בגודל ומיקום זהה, ורק פוקוס שונה בתלות אזור.

	Image_1	Image_2	Reference_Image
			
MDCT Level 1	Decomposition_IMG_1	Decomposition_IMG_2	Fused_Decomposition
	 IDCT_IMG1	 IDCT_IMG2	 Approx: mean Details: max
	Fused_Image	Error_Image	
	 Approx: mean Details: max		

	Decomposition_IMG_1	Decomposition_IMG_2	Fused_Decomposition
			 Approx: mean Details: max
			Error_Image
MDWT Level 1			
			 Approx: mean Details: max
MDCT Level 2			

			
	 Approx: mean Details: max		
MDWT Level 2	Decomposition_IMG_1	Decomposition_IMG_2	Fused_Decomposition
	 IDWT_IMG1	 IDWT_IMG2	 Mother Wavelet: db1 Approx: mean Details: max
	Fused_Image		Error_Image
	 Approx: mean Details: max		
	Fused_Image		Error_Image



Level of Decomposition	Algorithm	With reference image			Without reference image		
		PFE	PSNR	SSIM	CE	SD	SF
1	MDCT	3.7012	29.4315	0.9701	1.2062	45.9533	8.7602
1	MDWT	3.5579	29.7743	0.9737	7.2569	46.2713	10.4643
2	MDCT	3.3231	30.3675	0.9646	7.0789	46.4826	11.467
2	MDWT	3.0984	30.9754	0.9742	7.5978	47.0271	12.6106
4	MDCT	1.3315	38.3112	0.9906	1.6225	48.6852	13.1857
4	MDWT	2.2186	33.8768	0.9675	7.4041	49.0441	13.4315
8	MDCT	0.9726	41.0397	0.9936	1.0642	49.642	13.2462
8	MDWT	2.2214	33.8657	0.9665	5.5177	50.1258	13.4005

מסקנות :

ניתן לראות כי התמונות המאוחדות בעזרת MDCT וwavelet הן כמעט דומות עברו תמונות אלה. מודיעי הביצועים להערכת אלגוריתמי היתוך התמונה מוצגים בטבלה. המידדים המוצגים בטבלה עם צבע ירוק טובים יותר אחרים. הביצועים של MDCT כמעט דומים לאלו של wavelets. רמה גבוהה יותר של פירוק גוררת היפוך ביצועים, לפי טבלה עד לרמה 2 ביצועי של wavelets הם טובים יותר מזה של DCT (צבע צהוב), אך בפירוק יותר גבוהה ביצועים של DCT טובים יותר (צבע ירוק).

	Image_1	Image_2	
Original Images			
	Level 1 Fusion	Level 2 Fusion	Level 8 Fusion
MDCT	 Approx: mean Details: max	 Approx: mean Details: max	 Approx: mean Details: max
MDWT	 Approx: mean Details: max	 Approx: mean Details: max	 Approx: mean Details: max

Level of Decomposition	Algorithm	Without reference image		
		CE	SD	SF
1	MDCT	0.6753	60.7842	10.8101
1	MDWT	0.8117	60.8348	10.9403
2	MDCT	0.5923	60.9136	11.7342
2	MDWT	0.7668	60.9843	11.6317
4	MDCT	0.5831	61.102	11.9692
4	MDWT	0.6348	61.2286	11.8002
8	MDCT	0.6275	61.5079	11.9812
8	MDWT	0.6644	61.6061	11.7941

Original Images



	Level 1 Fusion	Level 2 Fusion	Level 8 Fusion
MDCT			
MDWT			

Level of Decomposition	Algorithm	Without reference image		
		CE	SD	SF
1	MDCT	0.7309	52.2889	14.848
1	MDWT	1.866	52.4083	14.9876
2	MDCT	1.8941	52.6687	16.4531
2	MDWT	1.5755	52.8318	16.3596
4	MDCT	3.0765	53.1818	16.8952
4	MDWT	1.8982	53.3519	16.6209
8	MDCT	2.4737	54.9649	16.9172
8	MDWT	1.5844	55.0508	16.6232

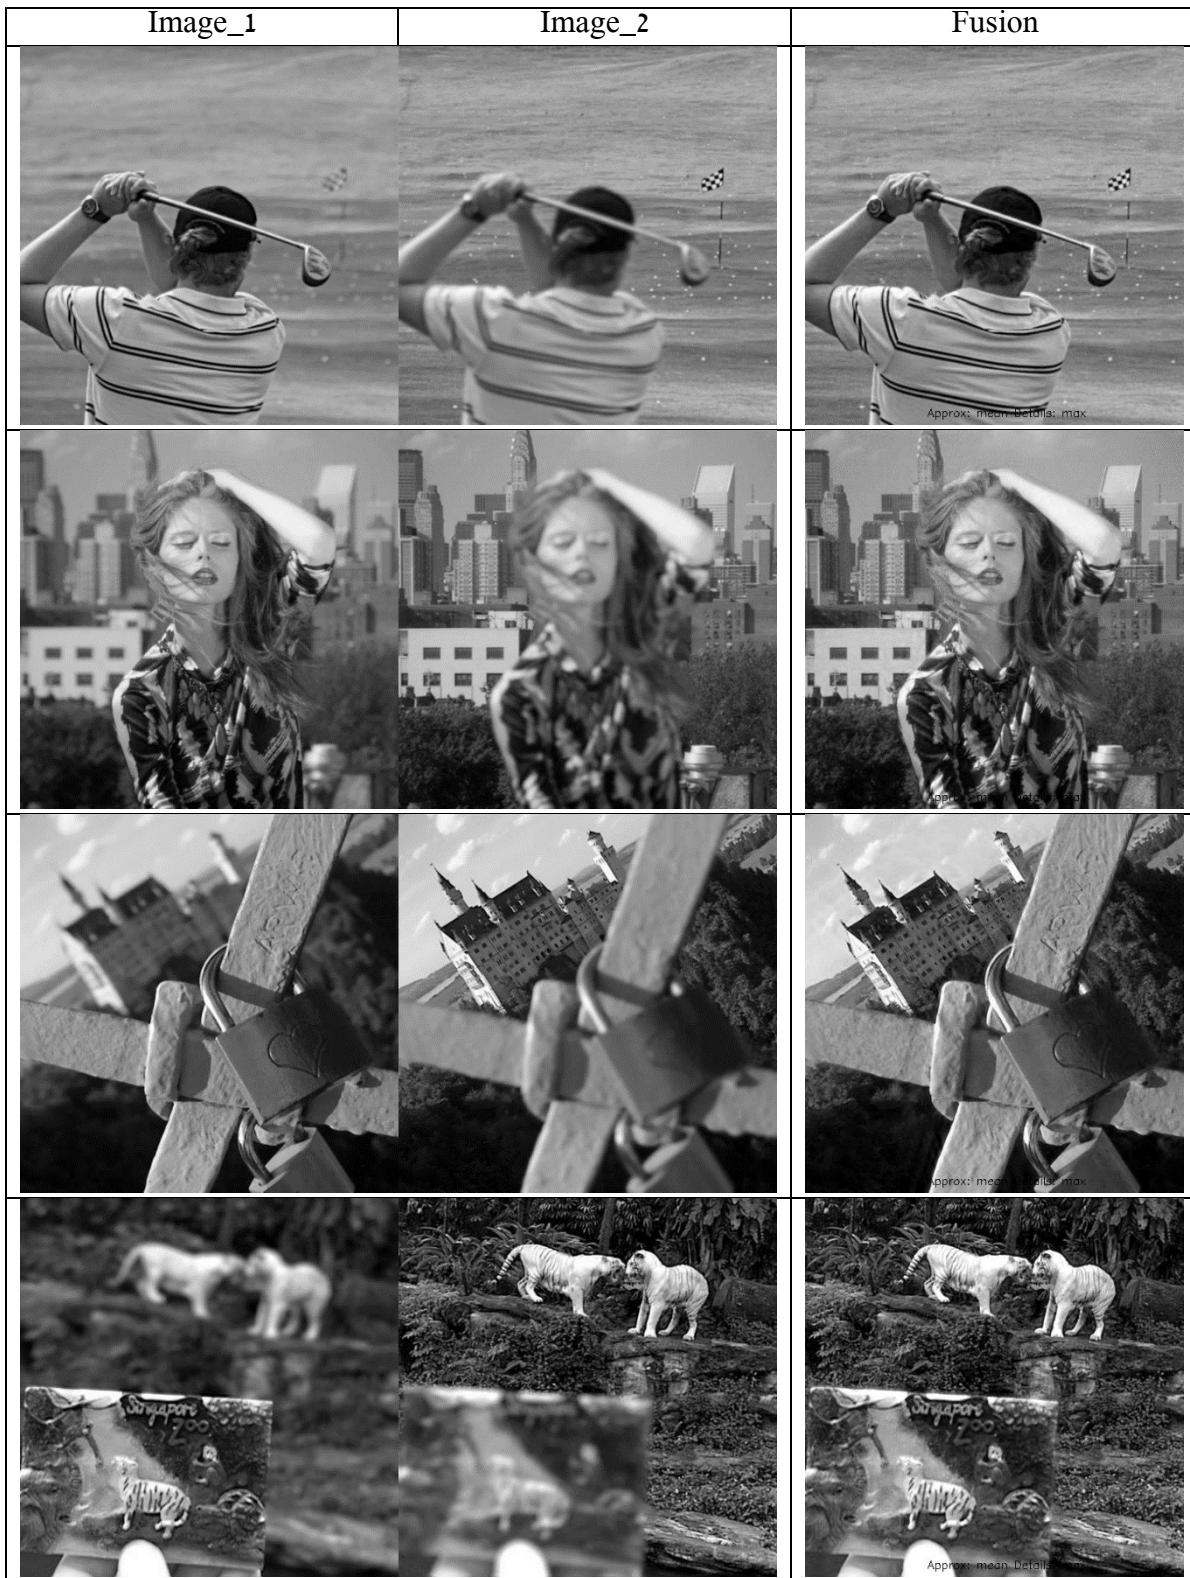


Level of Decomposition	Algorithm	Without reference image		
		CE	SD	SF
1	MDCT	0.0396	46.2209	8.537
1	MDWT	0.046	46.462	10.2323
2	MDCT	0.0593	46.6581	11.1503
2	MDWT	0.2761	47.1389	12.2903
4	MDCT	0.0832	48.4128	12.7545
4	MDWT	0.6317	48.9569	13.1278
8	MDCT	0.1045	49.8778	12.8213
8	MDWT	0.5437	50.2511	13.1017

עוד תמונות עברו DCT בלבד:

	Image_1	Image_2		
Original Images				
MDCT	Level 1 Fusion	Level 2 Fusion	Level 8 Fusion	
	Image_1	Image_2		
Original Images				
MDCT	Level 1 Fusion	Level 2 Fusion	Level 8 Fusion	

עוד תמונות עברו DCT עם עומק 8



מסקנות:

היתוך תמונה ברמת פיקסלים על ידי אלגוריתם MDCT יושם והוערך. הביצועים של אלגוריתם זה מושווים לטכנית היתוך תמונה ידועה על ידי wavelets. המסקנה היא שהיתוך תמונה על ידי MDCT דומה כמעט לויה של wavelets. זה מאד פשוט מבחינה חישובית והוא יכול להתאים היבר לישומים בזמן אמת. היתוך תמונה על ידי רמה גבוהה יותר של פירוק מספק תוצאות היתוך טובות יותר.

ניסויו לשלב תМОנות רפואיות :

	MRT	CT	
Original Images			
	Level 1 Fusion Approx: mean, Details: max	Level 1 Fusion Approx: min, Details: max	Level 7 Fusion Approx: mean, Details: max
MDCT			
MDWT			

[2]

הסבר על שימוש בGUI

GUI רשום בשפת פיתון

את GUI ניתן להפעיל באמצעות שני דרכי:

.1

בעזרת שימוש בקובץ py DCT - based Image Fusion.py או ב Visual Studio Code

יש לתקן ספריות הבאות (לעריץ פקודות) :

```
pip install tk
pip install numpy
pip install matplotlib
pip install scipy
pip install opencv-python
pip install scikit-image
pip install PyWavelets
pip install tabulate
```

.2

בעזרת הפעלת קובץ --.bat

* ראשית יש לחורץ את תיקיה למחשב ולבצע קומפקט

** לא נדרש להתקין ספריות

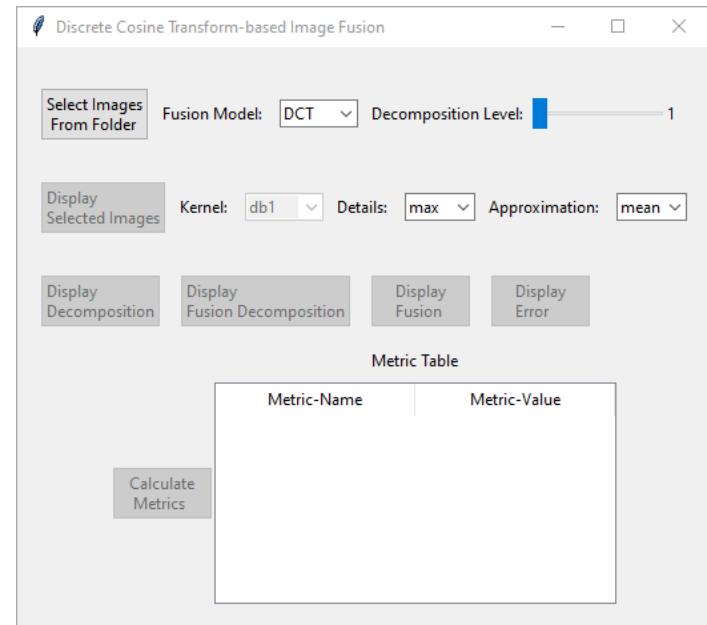
שימוש:

- Select Images from Folder – בחירה מרובע של תמונות בעזרת החזקת מקש CTRL ובחירה בעזרת עבר או סימון בעזרת עכבר בחזקת מקש שמאלי. ניתן לבחור מ2 עד 3 תמונות כאשר תמונה שלישית היא תמונה יcosa.

בעט בחירה של שני תמונות בלבד תאפשר לבחירה של כל הcptוררים פרט לכפטור Display Error, מכיוון שנדרש שתי תמונות יcosa.

- Display Selected Images – כפטור שיציג את תמונות שנבחרו, ** כדי להמשיך וללחוץ על cptוררים אחרים קודם יש לסגור את חלון הפתוח, סגירת חלון אפשרית בשלושה דרכים: 1) לחיצה מקש ESC 2) בעזרת עכבר בלחיצה על X 3) בעזרת לחיצה על מקש ימינו של עכבר כאשר סמן נמצא באזורי החלון פתוח.

- Display Decomposition - הצגת פירוק של תמונות שנבחרו להיתוך (תמונה ראשונה ושניה)



- Fusion Model – בחירת אלגוריתם היתוך, כאשר נבחר DWT תאפשר לשינוי Kernel ** לא נראה שיש הבדל!! [haar, db1] (Mother Wavelet)

- – רמת הפירוק של התמונות לצורך הייתוך [8-1], הפעלה רקורסיבית של פירוק על תמונה LL.
 - – בחירת אופן מייזוג של התמונות [min, max, mean] ו – Approximation Details ו – הציגת פירוק לאחר הייתוך, הייתוך מתבצע לפי בחירה של Display Fusion Decomposition ו – Approximation ו – Details.
 - – הציגת תמונה ממוגנת לאחר הייתוך Display Fusion.
 - – אופצייה הזאת קיימת רק בבחירה של שלוש תמונות כאשר תמונה שלישית היא תמונה ייחוס, מציגה שגיאה בין תמונה ממוגנת לתמונה ייחוס.
 - – הציגת מטריקות של עיליות של אלגוריתם, כאשר נבחרו רק שני תמונות (תמונה למייזוג) תוצג רק 3 מטריקות, וכאשר תבחר 3 תמונות תוצג 6 מטריקות.
- **כדי להמשיך וללחוץ על כפתורים אחרים קודם יש לסגור את חלון הפתוח, סגירת חלון אפשרית בשלושה דרכיים: 1) לחיצה מקש ESC 2)בעזרת עכבר בלחיצה על X 3) בעזרת לחיצה על מקש ימין של עכבר כאשר סמן נמצא באזור החלון פתוח.

- הקוד נמצא ב [Git](#)

References

- [1] L. Chen, yanyan liu, G. Li, jintao hong, J. Li, and J. Peng, “Double-function enhancement algorithm for low-illumination images based on retinex theory,” vol. 40, no. 2, pp. 316–316, Jan. 2023, doi: <https://doi.org/10.1364/josaa.472785> .
- [2] V. Naidu, “Discrete Cosine Transform-based Image Fusion,” Defence Science Journal, vol. 60, no. 1, pp. 48–54, Jan. 2010, doi: <https://doi.org/10.14429/dsj.60.105> .